

Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

Fase 1 (P1) — Grupo N° 1

Leonardo Candio Dimael Rivas

DS5345 · Aprendizaje por Refuerzo (2026-II)
Docente: Percy W. Lovón Ramos

Repositorio: <https://github.com/artrivas/RL-Project>

Tarea acotada: Ball Pursuit

- El jugador parte de posición y orientación arbitrarias, con el balón inmóvil a $d_0 \in [5, 40]$ m.
- Debe capturarlo ($d \leq 0.8$ m) en el menor tiempo posible.
- **Criterio de éxito:** tasa de captura > 90 % en menos de 40 pasos.
- Entorno principal: el cinemático del *starter kit* del curso.
 - DASH 100 avanza 1.0 m, DASH 50 avanza 0.5 m.
 - TURN ± 35 gira $\pm 35^\circ$ exactos, sin inercia ni ruido.
- Dos distribuciones de inicio: d_0 uniforme en $[5, 40]$ m y reset del kit ($d_0 \approx 11\text{--}19$ m).

MDP: estados y acciones

Estados: $s = (b_d(d), b_\theta(\theta))$ más terminal de captura. 9 zonas de distancia $\times$ 11 sectores de rumbo = **99 estados**, 396 valores Q .

- Rumbo: bordes en $\pm 2.5^\circ$, $\pm 7.5^\circ$, $\pm 17.5^\circ$, $\pm 35^\circ$, $\pm 90^\circ$. Justificados por la tolerancia angular $\arcsin(0.8/d)$ y la mitad del giro (17.5°).
- Distancia: bordes en 3, 6, 10, 15, 20, 25, 30, 35 m (3–5 pasos por zona).

Acciones: DASH 100, DASH 50, TURN +35, TURN -35.

MDP: transiciones, recompensa y descuento

- **Transiciones:** deterministas en $(\mathbf{x}, \phi)$, estocásticas sobre los bins (aliasing: un mismo bin agrupa posiciones con distinto futuro).
- **Recompensa** (enunciado): $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$. Con captura, maximizar G_0 equivale a capturar en menos pasos.
- **Descuento:** $\gamma = 0.99$ (el bono vale 67.6 en el paso 39; con 0.9 valdría 1.6). Truncamiento en 40 pasos con bootstrap desde s' .

Q-Learning: $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$, ε -greedy con desempate al azar.


- Comparación justa, mismo nivel final: $\varepsilon = 0.1$ constante vs.
 $\varepsilon_k = \max(0.1, 1.0 \cdot d^k)$, $d = 0.999952$.
- $\alpha = 0.1$, $\gamma = 0.99$, 80 000 episodios y 5 semillas por condición.
- Evaluación greedy cada 4 000 episodios sobre 500 inicios fijos en $[5, 40]$ m.
- Q-Learning, SARSA y Monte Carlo empatan ($\approx 85\%$); se reporta Q-Learning.

Resultado principal: ablación


Exploración	Final < 40 en [5, 40] m	Reset del kit
ε decreciente	0.857 ± 0.003	1.000 , 19.1 pasos
$\varepsilon = 0.1$ constante	0.843 ± 0.013	1.000, 19.3 pasos
<i>Óptimo exacto (A^*)</i>	<i>0.879</i>	<i>1.000, 18.6 pasos</i>

- El decreciente llega al 80 % en 12 000–16 000 episodios; el constante en 16 000–32 000.
- **Ninguna política supera el 87.9 % en [5, 40] m** (óptimo exacto): el 90 % no es alcanzable allí; la nuestra llega al 97.5 % del óptimo.


Evaluación greedy durante el entrenamiento



Retorno y éxito en entrenamiento




Política y valor aprendidos




- Avanza con DASH 100 entre -35° y $+17.5^\circ$; gira hacia el balón fuera de esa ventana.

Trayectorias: de erráticas a casi rectas


$d_0=14.5$ m, $\theta_0=-3^\circ$




$d_0=17.3$ m, $\theta_0=-62^\circ$



$d_0=18.0$ m, $\theta_0=122^\circ$



$d_0=12.6$ m, $\theta_0=-180^\circ$



- Política final ejecutada en el servidor real, 200 episodios por distribución, 0 comandos perdidos.
- Reset del kit: $26.0 \% \pm 3.1$ en vivo (la física real difiere del kit: avance gradual, giro con velocidad, ruido, visión parcial).
- Política entrenada con física del servidor: **$73.5 \% \pm 3.1$** en vivo en $[5, 40]$ m.
- Prueba de 500 episodios consecutivos sin errores de socket.

Otras tareas del catálogo (formulación)

	Conducción	Tiro	2v1
$ \mathcal{S} $	108	36	324
$ \mathcal{A} $	4	6	4
$ \mathcal{S} \times \mathcal{A} $	432	216	1 296
Criterio	> 30 m, > 80 %	> 75 % / > 50 %	> 50 pasos, $\geq$ 3 pases

- Misma cinemática simple del kit; propuesta formulada, pendiente de implementar.

- MDP tabular de 99 estados con discretización justificada por la geometría de captura.
- ε decreciente aprende antes y es más estable que el constante.
- Reset del kit: **100 % en todas las semillas** (19.1 pasos, óptimo 18.6).
- En $[5, 40]$ m el 90 % es inalcanzable (óptimo 87.9 %); llegamos a 85.7 %.
- Ejecución verificada en `rcssserver`.
- P2: DQN/PPO continuos, entrenar con física del servidor, recompensa consistente con el descuento.