

# Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

## Fase 1 (P1)

### Grupo N° [completar]

Integrantes:

Estudiante 1 (código) — Correo institucional

Estudiante 2 (código) — Correo institucional

Estudiante 3 (código) — Correo institucional

*Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>*

---

## Resumen

Formulamos la tarea de persecución de balón como un MDP tabular sobre el entorno cinemático del *starter kit* del curso: 99 estados (distancia y rumbo del balón) y 4 macro-acciones. Entrenamos Q-Learning con distancias iniciales en todo el rango del enunciado,  $d_0 \in [5, 40]$  m. Con el reset del kit ( $d_0 \approx 11$ –19 m) la política captura el **100 %** de los balones en menos de 40 pasos en las 5 semillas, en 19.1 pasos (el óptimo exacto es 18.6). En el rango completo captura el  $85.7 \% \pm 0.3$ . Calculamos por búsqueda exacta que **ninguna política puede superar el 87.9 %** en ese rango, así que el 90 % no es alcanzable allí y nuestra política llega al 97.5 % del óptimo. La exploración  $\epsilon$  decreciente aprende antes que la constante (80 % en 12 000–16 000 episodios frente a 16 000–32 000). Validamos la ejecución conectando el cliente a `rcssserver`.

## 1. Introducción y Descripción de la Tarea

Elegimos la tarea acotada de **persecución e intercepción de balón**: el jugador parte de una posición y orientación arbitrarias, con el balón inmóvil a  $d_0 \in [5, 40]$  m, y debe capturarlo ( $d \leq 0.8$  m) en el menor tiempo posible. El criterio de éxito es una tasa de captura  $> 90 \%$  en menos de 40 pasos.

Como P1 consiste en tareas acotadas, usamos como **entorno principal el del starter kit** entregado por el profesor (`agente_cero_mc_control_persecucion.ipynb`), reimplementado fielmente en `src/kit_env.py`:

- DASH 100 avanza exactamente 1.0 m y DASH 50, 0.5 m;
- TURN  $\pm 35$  gira exactamente  $\pm 35^\circ$ ;

- no hay inercia ni ruido, y el agente observa la distancia y el rumbo verdaderos.

Evaluamos con dos distribuciones de inicio:

- **[5, 40] m:**  $d_0$  uniforme sobre el rango del enunciado, con posición y orientación arbitrarias. Se usa para entrenar y para la evaluación periódica.
- **Reset del kit:** jugador cerca de  $(-15, 0)$  y balón cerca del centro, así que  $d_0 \approx 11\text{--}19\text{ m}$ .

El simulador real [2, 4] es un POMDP más difícil: inercia, giros que dependen de la velocidad, ruido y visión parcial. Lo usamos para **validar la transferencia**, conectando el cliente Python a `rcssserver` (Docker, `docker compose up -d`). El servidor corre controlado por un entrenador (coach offline), que resetea los episodios y mide la verdad de terreno.

## 2. Modelado Formal como MDP

**Espacio de estados ( $\mathcal{S}$ ).** El agente observa  $(d, \theta)$ : la distancia al balón y su rumbo relativo al cuerpo. El estado es  $s = (b_d(d), b_\theta(\theta))$ , más un estado terminal de captura. Usamos 9 zonas de distancia y 11 sectores de rumbo:  $|\mathcal{S}| = 9 \times 11 = 99$  estados y  $99 \times 4 = 396$  valores  $Q$  (Tabla 1).

| Componente       | Bordes                                                                     | Justificación                                                                                                                                                                                                                                                                                                                                                                         |
|------------------|----------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Rumbo $b_\theta$ | $\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$ | La tolerancia angular de captura es $\arcsin(0.8/d)$ : $4.6^\circ$ a 10 m, $2.3^\circ$ a 20 m y $1.5^\circ$ a 30 m. Por eso se diseñaron sectores finos cerca del frente (aunque la política aprendida no cambia de acción entre ellos; §5). $17.5^\circ$ es la mitad del giro de $35^\circ$ (el error máximo tras girar), $35^\circ$ es un giro y $90^\circ$ separa delante/-detrás. |
| Distancia $b_d$  | 3, 6, 10, 15, 20, 25, 30, 35 m                                             | Con 1 m por paso, cada zona equivale a 3–5 pasos de tiempo restante frente al presupuesto de 40. Las zonas son más finas cerca, donde se decide la maniobra final.                                                                                                                                                                                                                    |

Tabla 1: Discretización del estado (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

**Espacio de acciones ( $\mathcal{A}$ ).**  $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$ . En el kit, con posición  $\mathbf{x}$  y rumbo  $\phi$ : **DASH**  $p$ :  $\mathbf{x} += \ell_p(\cos \phi, \sin \phi)$  con  $\ell_{100} = 1\text{ m}$  y  $\ell_{50} = 0.5\text{ m}$ ; **TURN**  $\pm 35$ :  $\phi += \pm 35^\circ$ .

**Transiciones ( $\mathcal{P}$ ).** Sobre el estado continuo  $(\mathbf{x}, \phi)$  la dinámica es determinista. Sobre los bins,  $\mathcal{P}(s' | s, a)$  es estocástica porque el estado no conserva la posición exacta dentro del bin. Un **TURN**  $+35$  lleva al frente un balón a  $30^\circ$ , pero no uno a  $80^\circ$ , aunque ambos estén en el mismo bin. Es aliasing de estados;  $\mathcal{S}$  es una aproximación, no un estado de Markov exacto.

**Recompensa ( $\mathcal{R}$ ).** La del enunciado:  $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$ . Con  $\gamma = 1$  el término de aproximación es telescópico:  $G_0 = (d_0 - d_T) - 0.2T + 100 \cdot \mathbb{I}\{\text{captura}\}$ . Con captura,  $d_T$  es casi constante, así que maximizar  $G_0$  equivale a capturar en el menor número de pasos. El moldeado basado en potencial con  $\Phi = -d$  sería  $d_t - \gamma d_{t+1}$  [3]. Con  $\gamma < 1$  no afirmamos invariancia de la política.

**Descuento y horizonte.**  $\gamma = 0.99$ : el bono de captura vale  $100 \cdot 0.99^{39} = 67.6$  en el paso 39; con  $\gamma = 0.9$  valdría solo 1.6. El episodio termina con la captura (sin bootstrap) o se trunca en  $T_{max} = 40$  pasos. En el truncamiento se hace bootstrap desde  $s'$ , porque el tiempo no forma parte del estado [6].

### 3. Algoritmo de Aprendizaje por Refuerzo

**Q-Learning** [5, 1]:  $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ , sin bootstrap en estados terminales, con acciones  $\varepsilon$ -greedy y desempate al azar. Comparamos dos exploraciones con el mismo nivel final:

- $\varepsilon = 0.1$  constante;
- $\varepsilon_k = \max(0.1, 1.0 \cdot d^k)$  con  $d = 0.999952$ , que llega al mínimo al 60 % del presupuesto.

**Hiperparámetros.**  $\alpha = 0.1$ ,  $\gamma = 0.99$ , 80 000 episodios por corrida y 5 semillas por condición. Cada 4 000 episodios evaluamos la política greedy ( $\varepsilon = 0$ , sin aprendizaje) sobre 500 inicios fijos en [5, 40] m. Al final, evaluamos la Q-table también sobre 500 inicios del reset del kit. Guardamos la Q-table, el historial y la configuración de cada corrida.

**Selección.** Con R3 y las mismas condiciones, Q-Learning, SARSA y Monte Carlo first-visit (el algoritmo del kit) terminan empatados dentro del ruido entre semillas:  $\approx 85$  % en [5, 40] m y 100 % con el reset del kit. SARSA y MC alcanzan el 70 % antes. Reportamos Q-Learning.

### 4. Resultados Experimentales y Análisis

**Fidelidad al kit.** Con la configuración del notebook del kit (MC first-visit, 3 500 episodios,  $\varepsilon = \max(0.05, 0.998^k)$ , su discretización y su reset), nuestro entorno da  $89.2 \pm 17.2$  (entre 44.8 % y 100 %) de éxito greedy en 8 semillas. Un resultado de una sola semilla, como el 100 % de la semilla 42 del código original, no es representativo; por eso reportamos siempre 5 semillas.

**Máximo alcanzable.** El kit es determinista, así que para cada inicio calculamos el mínimo exacto de pasos hasta capturar sobre todas las secuencias de acciones: una búsqueda  $A^*$  con heurística admisible sobre posición y rumbo, 1 000 inicios por distribución y ningún caso indeterminado. Con el reset del kit el óptimo captura el 100 % en 18.6 pasos de media. En [5, 40] m **ninguna política puede superar el  $87.9 \pm 1.0$** .

**Ablación de la exploración.** La Tabla 2 y la Figura 1 resumen la ablación.

**Política, valor y trayectorias.** La Figura 3 muestra  $\hat{\pi}(s)$  y  $\hat{V}(s) = \max_a Q(s, a)$ ; son estimaciones aprendidas, no óptimos demostrados. La política avanza (DASH 100) cuando el balón está entre  $-35^\circ$  y  $+17.5^\circ$  y gira hacia él fuera de esa ventana, igual en casi todas las distancias. La ventana es más ancha que un giro de  $35^\circ$ , así que tras girar el balón queda dentro y el agente no oscila. La corrección fina ocurre por la geometría de la aproximación: al acercarse con un pequeño error, el rumbo del balón crece hasta cruzar un umbral y el agente gira. La Figura 4 muestra la política greedy guardada a lo largo del entrenamiento: las trayectorias pasan de erráticas a casi rectas.

| Exploración                   | $d_0 \in [5, 40]$ m                 |                         |           | Reset del kit                       |             |
|-------------------------------|-------------------------------------|-------------------------|-----------|-------------------------------------|-------------|
|                               | Final < 40                          | Episodios a 70 % / 80 % | $\leq 40$ | Captura < 40                        | Pasos       |
| $\varepsilon$ decreciente     | <b><math>0.857 \pm 0.003</math></b> | <b>12k / 12k–16k</b>    | 0.876     | <b><math>1.000 \pm 0.000</math></b> | <b>19.1</b> |
| $\varepsilon = 0.1$ constante | $0.843 \pm 0.013$                   | 16k / 16k–32k           | 0.863     | $1.000 \pm 0.000$                   | 19.3        |
| <i>Óptimo exacto</i>          | <i>0.879</i>                        |                         |           | <i>1.000</i>                        | <i>18.6</i> |

Tabla 2: Ablación en el entorno del kit (Q-Learning, R3, greedy, 5 semillas). En  $[5, 40]$  m,  $G_0 = 104.1$  con 26.3 pasos (decreciente) y  $G_0 = 102.2$  con 26.6 pasos (constante).




Figura 1: Evaluación greedy durante el entrenamiento sobre 500 inicios fijos en  $[5, 40]$  m (media  $\pm$  desv. est. en 5 semillas). Referencias: criterio de 90 % y óptimo exacto (87.9 %).




Figura 2: Retorno  $G_0$  y tasa de éxito de los episodios de entrenamiento (con exploración), media móvil de 500 episodios.




Figura 3: Política greedy  $\hat{\pi}(s)$  (izq.) y valor  $\hat{V}(s)$  (der.) aprendidos en el entorno del kit (R3). Filas: distancia; columnas: rumbo relativo.




Figura 4: Trayectorias 2D de la política greedy tras  $N$  episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

**Transferencia a rcssserver.** Ejecutamos la política final en el servidor real, 200 episodios por distribución, con 0 comandos perdidos y 0 errores de reset. Con el reset del kit captura el  $26.0 \% \pm 3.1$  ( $26.0 \%$  en nuestro simulador con física del servidor); en  $[5, 40]$  m, el  $20.5 \% \pm 2.9$  ( $21.0 \%$  en el simulador).

## 5. Discusión y Análisis de Ablación

**Impacto de la discretización.** Es el factor que más pesó. En  $[5, 40]$  m, con 5 semillas:

- **Discretización del kit** (20 estados, cortes en  $0.8/3/8$  m y  $15^\circ/60^\circ$ ):  $56.6 \%$ , y bimodal con su propio reset (según la semilla,  $\approx 98 \%$  o  $\approx 46 \%$ ).
- **Nuestra primera versión** (20 estados, alineada con el giro de  $35^\circ$ ):  $61.0 \%$ .
- **R3** (99 estados):  $84.7 \%$  con 80 000 episodios.
- **R4**, aún más fina (150 estados): cae a  $81.0 \%$ , porque tiene demasiados estados para el presupuesto de entrenamiento.

No aislamos qué componente de R3 explica la mejora. Agregar solo un sector de  $\pm 5^\circ$  (R1, 28 estados) no ayudó. R3 añade además un borde en  $35^\circ$  y más zonas de distancia, y su política usa una ventana de avance asimétrica,  $[-35^\circ, +17.5^\circ]$ , que una rejilla sin borde en  $35^\circ$  no puede representar. Es una explicación compatible con los datos, no una demostración.

**Efecto del decaimiento de la exploración.** Con el reset del kit ambas exploraciones llegan a  $100 \%$ . En el rango completo, el  $\varepsilon$  decreciente alcanza el  $70 \%$  en 12 000 episodios en todas las semillas, frente a 16 000 del constante, y el  $80 \%$  en 12 000–16 000 frente a 16 000–32 000. También termina algo más alto y con menos varianza ( $85.7 \% \pm 0.3$  frente a  $84.3 \% \pm 1.3$ ). Explorar mucho al inicio y poco al final aprende antes y de forma más fiable.

**El criterio de  $90 \%$ .** Con el reset del kit el criterio se cumple con holgura:  $100 \%$  en todas las semillas, a medio paso del óptimo exacto. En el rango completo  $[5, 40]$  m con  $d_0$  uniforme, el  $90 \%$  **no es alcanzable en este entorno**: el óptimo exacto es  $87.9 \%$ . Por distancia, sobre los mismos 1 000 inicios, la política captura el  $100 \%$  hasta 30 m, igual que el óptimo. Toda la diferencia está más lejos:  $85.7 \%$  frente a  $90.5 \%$  entre 30 y 35 m, y  $8.2 \%$  frente a  $18.7 \%$  entre

35 y 40 m, donde ni la mejor política posible llega a tiempo en la mayoría de los casos. En total, nuestra política llega al 85.7 %, el 97.5 % del máximo. El enunciado fija el rango de  $d_0$  pero no su distribución; con inicios concentrados en distancias cortas, como el reset del kit, el criterio se cumple.

**Transferencia y limitaciones.** El kit es una idealización. En el servidor hay inercia (el avance crece de 0.6 a 1 m por ciclo), el giro se reduce con la velocidad, hay ruido y la visión es parcial, y la política del kit pierde rendimiento ( $26.0 \% \pm 3.1$  con el reset del kit). Como extensión, entrenamos Q-Learning con la física del servidor, observando solo lo que percibe el jugador y con un bit de velocidad en el estado. Esa política alcanza el  $73.5 \% \pm 3.1$  en vivo en  $[5, 40]$  m, frente al 71.5 % en su simulador, y una prueba de estabilidad de 500 episodios consecutivos en vivo no registró errores de socket. El límite del enfoque tabular es el aliasing: más estados mejoran la puntería, pero exigen más datos (R4 rindió menos que R3). Eso motiva aproximadores continuos en P2.

## 6. Conclusiones

- **Formulación:** un MDP tabular de 99 estados, con una discretización justificada a partir de la tolerancia angular de captura y del giro de  $35^\circ$ .
- **Exploración:** Q-Learning con  $\varepsilon$  decreciente aprende antes y es algo más estable que con  $\varepsilon$  constante.
- **Criterio:** con el reset del kit se supera el 90 % (100 % en todas las semillas, 19.1 pasos). En el rango completo  $[5, 40]$  m el 90 % no es alcanzable para ninguna política (óptimo exacto 87.9 %), y la nuestra llega al 85.7 %, el 97.5 % de ese óptimo.
- **Transferencia:** la ejecución se verificó en `rcssserver`; con física real el rendimiento de la política del kit baja, y una política entrenada con esa física alcanza el 73.5 %.

Para P2 proponemos:

- aproximadores continuos (DQN/PPO) sobre  $(d, \theta, v)$ , sin el costo en datos de una tabla fina;
- entrenar directamente con la física del servidor;
- un moldeado de recompensa consistente con el descuento.

## Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.

- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.
- [4] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] F. Pardo, A. Tavakoli, V. Levdik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.