

Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

Fase 1 (P1)

Grupo N° [completar]

Integrantes:

Estudiante 1 (código) — Correo institucional

Estudiante 2 (código) — Correo institucional

Estudiante 3 (código) — Correo institucional

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos la tarea de persecución de balón de RoboCup 2D como un MDP con 41 estados discretos (distancia y rumbo estimados del balón, velocidad propia y un estado de balón no adquirido) y 4 macro-acciones. El agente usa solo lo que percibe el jugador. Entrenamos Q-Learning tabular en un simulador construido con los parámetros físicos de `rcssserver` y validado contra el servidor. La exploración ε decreciente ($1.0 \rightarrow 0.1$) supera a $\varepsilon = 0.1$ constante: $73.8 \% \pm 0.6$ frente a $70.0 \% \pm 3.7$ de captura greedy en menos de 40 pasos (5 semillas), con retorno $G_0 \approx 91.6$ y 29.5 pasos por episodio. En el servidor real la política captura el $73.5 \% \pm 3.1$ (97.8 % bajo 30 m). Con 1 paso = 1 ciclo de 100 ms y distancia inicial uniforme no alcanza el criterio de 90 %. Con dos lecturas alternativas del enunciado, que no fija esos supuestos, lo supera en el servidor.

1. Introducción y Descripción de la Tarea

Elegimos la tarea acotada de **persecución e intercepción de balón**: el jugador parte de una posición y orientación arbitrarias, con el balón inmóvil a $d_0 \in [5, 40]$ m, y debe capturarlo ($d \leq 0.8$ m) en el menor tiempo posible. El criterio de éxito del enunciado es una tasa de captura $> 90 \%$ en menos de 40 pasos.

La dificultad está en la física y la percepción del simulador [2, 4]:

- **Inercia:** la velocidad decae a 0.4 por ciclo y la de crucero es ≈ 1 m/ciclo.
- **Giro dependiente de la velocidad:** TURN 35 gira 35° en reposo, pero solo $\approx 12^\circ$ en movimiento.
- **Ruido:** de $\pm 10 \%$ en giros y velocidad.

- **Observabilidad parcial:** cono visual de 90° , y un mensaje de visión en 2 de cada 3 ciclos que puede llegar después del plazo de decisión.
- **Tiempo real:** un comando cada 100 ms.

Objetivos: (i) formular el MDP y justificar la discretización; (ii) implementar un baseline tabular con ablación de la exploración; (iii) validarlo conectando el cliente Python a `rcssserver`.

Infraestructura. Todo corre en Docker (`docker compose up -d`). El servidor corre controlado por un entrenador (coach offline), que resetea cada episodio y mide la verdad de terreno; esa información nunca llega a la política. Entrenamos en un simulador rápido construido con los parámetros que el servidor reporta en el handshake. Contra el servidor, reproduce secuencias fijas de acciones con un sesgo de posición ≤ 0.16 m, menor que la dispersión propia del servidor (hasta 0.31 m). Mide un giro medio en reposo de $35.03^\circ \pm 0.16$ ($n = 180$), y la política heurística de referencia captura el 67.2 % en vivo frente al 67.6 % simulado sobre los mismos 500 inicios.

2. Modelado Formal como MDP

Espacio de estados ($\mathcal{S}$). Un estimador (`perception.py`) combina los avistamientos del balón con la odometría del `sense_body` y entrega la distancia y el rumbo estimados ($\hat{d}, \hat{\theta}$) relativos al cuerpo. El estado es

$$s = (b_d(\hat{d}), b_\theta(\hat{\theta}), b_v(v)) \cup \{\text{DESCONOCIDO}\},$$

más un estado terminal de captura sin entradas en Q . La Tabla 1 justifica cada borde desde la dinámica. La cardinalidad es $|\mathcal{S}| = 4 \times 5 \times 2 + 1 = 41$ y la tabla Q tiene $41 \times 4 = 164$ valores. Con $\approx 600\,000$ transiciones por corrida, cada par (s, a) recibe en promedio unas 3 600 actualizaciones. El enunciado sugiere $|\mathcal{S}| \approx 20$; lo ampliamos con el bit de velocidad y el lado posterior.

Componente	Bordes	Justificación
Distancia b_d	3, 10, 20 m	3 m = <code>visible_distance</code> (el balón se percibe en cualquier dirección; quedan ≈ 3 ciclos). A ≈ 1 m/ciclo, 10 y 20 m separan regímenes de tiempo restante frente a 40 pasos.
Rumbo b_θ	$\pm 17.5^\circ$, $\pm 90^\circ$	$\pm 17.5^\circ$ es la mitad del cuanto de giro (35°): cualquier rumbo puede llevarse al frente girando en reposo. $\pm 90^\circ$ separa delante/detrás: detrás, avanzar aleja.
Velocidad b_v	0.2 m/ciclo	El giro efectivo cae de 35° a $\approx 12^\circ$ con la velocidad; sin este bit, un mismo estado exige acciones distintas.
DESCONOCIDO	1 estado	Balón aún no adquirido: la búsqueda inicial queda dentro de la política.

Tabla 1: Discretización del estado. Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

$\mathcal{S}$ es una **aproximación**, no un estado de Markov exacto: la posición dentro de un bin, la velocidad exacta y la observabilidad parcial quedan ocultas. Es aliasing de estados propio de discretizar un POMDP continuo.

Espacio de acciones ($\mathcal{A}$). $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$, una por ciclo. Con

velocidad $\mathbf{v}$, rumbo ϕ y ruido $\epsilon \sim U[-0.1, 0.1]$:

$$\begin{aligned} \text{DASH } p : \mathbf{v} &+= 0.006 p (\cos \phi, \sin \phi), & \text{TURN } m : \phi &+= \frac{m(1 + \epsilon)}{1 + 5\|\mathbf{v}\|}, \\ \text{luego, en cada ciclo: } \|\mathbf{v}\| &\leq 1.05, & \mathbf{x} &+= \mathbf{v}, & \mathbf{v} &\leftarrow 0.4 \mathbf{v}. \end{aligned}$$

Transiciones ($\mathcal{P}$). $\mathcal{P}(s' | s, a)$ no tiene forma cerrada sobre los bins: resulta de componer la dinámica anterior, el ruido, la visión y el estimador. Con el balón inmóvil es casi determinista dentro de cada bin; la estocasticidad viene del ruido, de la posición exacta dentro del bin y de la visión parcial. La estimamos empíricamente en el simulador. Por ejemplo, con el balón a la derecha a 10–20 m, TURN +35 lo lleva al frente con probabilidad 0.38 en reposo y 0.23 en movimiento. La misma acción tiene efectos distintos según la velocidad, y eso motiva b_v .

Recompensa ($\mathcal{R}$). Usamos la del enunciado, calculada con la distancia verdadera: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$. Con $\gamma = 1$ el término de aproximación es telescópico: $G_0 = (d_0 - d_T) - 0.2T + 100 \cdot \mathbb{I}\{\text{captura}\}$. Si hay captura, d_T es casi constante, así que maximizar G_0 equivale a capturar en el menor número de pasos. Sin captura, el agente recibe crédito por la distancia recortada. El moldeado basado en potencial con $\Phi = -d$ sería $d_t - \gamma d_{t+1}$ [3]. Como $\gamma < 1$ y el estado es aproximado, no afirmamos invariancia de la política.

Descuento, horizonte y episodio. $\gamma = 0.99$: el bono de captura vale todavía $100 \cdot 0.99^{39} = 67.6$ en el paso 39. Con $\gamma = 0.9$ valdría 1.6, del orden de una sola recompensa de aproximación. El episodio termina con la captura (sin bootstrap) o se trunca en $T_{max} = 40$ pasos. En el truncamiento se hace bootstrap desde s' , porque el tiempo transcurrido no forma parte del estado [6].

Nuestra interpretación del enunciado es: **1 paso = 1 ciclo del servidor** (100 ms), y los inicios se muestrean con $d_0 \sim U[5, 40]$ m y rumbo relativo y orientación uniformes. El enunciado fija el rango de d_0 , pero ni la duración del paso ni la forma de la distribución (Sección 5).

3. Algoritmo de Aprendizaje por Refuerzo

Q-Learning [5, 1] off-policy, con actualización

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)],$$

sin el término de bootstrap en estados terminales. Las acciones se eligen ϵ -greedy, desempataando al azar. Comparamos dos políticas de exploración con el mismo nivel final:

- $\epsilon = 0.1$ constante;
- $\epsilon_k = \max(0.1, 1.0 \cdot d^k)$ con $d = 0.999808$, que alcanza el mínimo al 60 % del presupuesto.

Hiperparámetros. $\alpha = 0.03$, $\gamma = 0.99$, 20 000 episodios por corrida y 5 semillas por condición. Cada 1 000 episodios se evalúa la política greedy ($\epsilon = 0$, sin aprendizaje) sobre 500 inicios fijos, con el mismo flujo de ruido del simulador en todas las condiciones. Cada corrida guarda su Q-table, historial y configuración completa. Elegimos $\alpha = 0.03$ porque con $\alpha = 0.1$ la política greedy colapsaba periódicamente bajo aliasing (Sección 5).

También probamos SARSA y Monte Carlo first-visit en condiciones idénticas. Elegimos Q-Learning por su mayor tasa de captura y menor varianza entre semillas: 73.9 %, frente a 72.0 % de SARSA y 68.1 % de MC.

4. Resultados Experimentales y Análisis

Curvas de aprendizaje y ablación. La Figura 1 muestra la evaluación greedy durante el entrenamiento y la Tabla 2 resume la ablación. La Figura 2 muestra el retorno G_0 y la tasa de éxito de los episodios de entrenamiento (con exploración), suavizados con una media móvil de 500 episodios porque cada corrida tiene 20 000.




Figura 1: Evaluación greedy sobre 500 inicios fijos (media $\pm$ desv. est. en 5 semillas). Líneas de referencia: criterio de 90 % y controlador heurístico evaluado sobre los mismos inicios.

Exploración	Final < 40	Últimas 5	Peor	G_0	Pasos	Episodios hasta 70 %
ε decreciente	0.738 $\pm$ 0.006	0.739 $\pm$ 0.007	0.708	91.6	29.5	6k–13k (5/5)
$\varepsilon = 0.1$ constante	0.700 $\pm$ 0.037	0.669 $\pm$ 0.073	0.464	88.1	30.3	10k–12k (3/5)

Tabla 2: Ablación de la exploración (simulador, greedy, 5 semillas). “Últimas 5”: media de las 5 últimas evaluaciones. “Peor”: la peor de ellas en cualquier semilla. G_0 y pasos: medias de la evaluación final.

Eficiencia. La política final usa en promedio 29.5 pasos por episodio en el simulador y 30.1 en el servidor. Esos promedios incluyen los episodios truncados en 40.

Política y valor aprendidos. La Figura 3 muestra $\hat{\pi}(s)$ y $\hat{V}(s) = \max_a Q(s, a)$ en reposo. Son estimaciones aprendidas, no óptimos demostrados. La política es físicamente coherente: gira hacia el balón (TURN +35 si está a la derecha, TURN -35 a la izquierda) y avanza cuando lo tiene de frente. $\hat{V}$ cae para balones detrás del jugador y lejanos.

Trayectorias durante el aprendizaje, en el servidor. Guardamos la Q-table a lo largo del entrenamiento y ejecutamos cada instantánea en `rcssserver` (Figura 4). Sobre 4 inicios fijos, la política greedy captura 1, 0, 1, 3, 4, 4 y 4 balones tras 0, 500, 1 000, 2 000, 5 000, 10 000 y 20 000 episodios. Las trayectorias pasan de erráticas a casi rectas.




Figura 2: Retorno G_0 (izq.) y tasa de éxito (der.) de los episodios de entrenamiento, con media móvil de 500 episodios. La condición decreciente parte más baja porque explora casi al azar al inicio.




Figura 3: Política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$ (der.) aprendidos, con el bit de velocidad en reposo. Filas: distancia; columnas: rumbo relativo.




Figura 4: Política greedy tras N episodios de entrenamiento, ejecutada en `rcssserver` (posiciones medidas por el entrenador). Claro = temprano, oscuro = tarde. Círculo blanco: balón.

Validación en el servidor. En 500 episodios consecutivos en vivo (15 588 ciclos) hubo 0 comandos fuera de su ciclo, 0 errores de reset y 0 cambios de modo de juego. La Tabla 3 compara simulador y servidor sobre los mismos inicios. La política aprendida captura el **73.5 % $\pm$ 3.1** en vivo; sus fallos se concentran en inicios lejanos (Figura 5).

Política	n	Servidor < 40	Simulador < 40	Servidor $\leq$ 40
Q-Learning (ε decreciente)	200	73.5 % $\pm$ 3.1	71.5 %	76.5 %
Controlador heurístico	500	67.2 % $\pm$ 2.1	67.6 %	69.8 %

Tabla 3: Evaluación en vivo frente al simulador sobre los mismos inicios (1 paso = 1 ciclo, d_0 uniforme). Los inicios en vivo son distintos de los usados para elegir la semilla evaluada.




Figura 5: Tasa de captura en menos de 40 pasos según la distancia inicial, en el servidor y en el simulador.

5. Discusión y Análisis de Ablación

Impacto de la discretización. Comparamos representaciones bajo condiciones idénticas (últimas 5 evaluaciones, 5 semillas):

- **Frente de $\pm 10^\circ$:** 57.4 %. La política oscila entre giros, porque en reposo solo se alcanzan rumbos separados 35° .
- **Frente de $\pm 17.5^\circ$:** 69.7 %.
- **$\pm 17.5^\circ$ más el bit de velocidad:** 71.4 %, y su peor evaluación sube de 19 % a 57 %.
- **Con $\alpha = 0.03$:** 73.9 %, y la peor evaluación sube a 71 %.
- **Representaciones más finas:** frente de $\pm 5^\circ$ o $\pm 7^\circ$, un borde en 30 m, o un frente que depende de la velocidad. Con el doble de episodios no mejoraron el promedio y desestabilizaron algunas semillas.

Un detalle conocido: la velocidad de cruce de DASH 50 tras el decaimiento es exactamente 0.2, el borde del bit de velocidad. La política aprendida casi no usa esa acción.

Efecto del decaimiento de la exploración. El ε decreciente alcanza 70 % en las 5 semillas (entre 6 000 y 13 000 episodios) y termina estable (peor evaluación: 70.8 %). Con $\varepsilon = 0.1$ constante, 2 de 5 semillas nunca llegan a 70 % y la política colapsa ocasionalmente (peor evaluación: 46.4 %). Explorar mucho al inicio y poco al final da políticas mejores y más estables con el mismo presupuesto.

Limitaciones del enfoque tabular. En el simulador, todos los algoritmos y representaciones probados se estancan cerca de 75 %: la mejor evaluación individual queda entre 74 y 75 %, aunque el promedio y la estabilidad difieren. El aliasing es visible: sin el bit de velocidad, y con α alto, la política greedy colapsa. Estas observaciones describen las configuraciones probadas y no establecen un techo universal. Ajustar el rumbo con precisión a larga distancia exige distinguir estados que la tabla agrupa, lo que motiva aproximadores continuos en P2.

El criterio de 90 %. Por distancia inicial, en vivo la política captura 135/138 (97.8 %) bajo 30 m, 12/36 (33.3 %) entre 30 y 35 m, y 0/26 sobre 35 m. Bajo d_0 uniforme, incluso con 100 % de captura bajo 30 m, superar 90 % exigiría más de 65 % de éxito entre 30 y 40 m.

Un análisis de sensibilidad de la misma política (simulador, sin reentrenar) muestra cuánto pesa cada supuesto:

- **Presupuesto de tiempo:** con 45 o 50 ciclos la tasa sube a 86.8 % y 97.1 %. Con hasta 10 ciclos más, 9 de cada 10 fallos se convierten en capturas.
- **Posición inicial del balón:** darla al inicio sube la tasa a 79.8 %, igual que darla en cada paso (79.7 %). La pérdida está en la búsqueda inicial, no en el seguimiento.
- **Forma de la distribución de d_0 :** sobre el mismo rango, la tasa va de 59 % a 93 %.

No afirmamos que el criterio sea imposible: una cota demostrable, sin ruido, deja un techo de 94.9 %, y con ruido no hay imposibilidad estricta. Tampoco afirmamos que la interpretación explique todo el déficit, ni que no haya errores de implementación.

Lecturas alternativas del enunciado. El enunciado no fija la duración de un “paso” (habla de macro-acciones) ni la forma de la distribución de d_0 . Evaluamos en el servidor dos lecturas, con definiciones explícitas (notebook 06):

- **d_0 concentrado en distancias cortas.** Densidad triangular $\propto (40 - d)$ sobre $[5, 40]$ m. La misma política, sin reentrenar, captura el **92.5 % $\pm$ 1.9** en el servidor (92.5 % en el simulador; 200 episodios).
- **1 paso = k ciclos.** La acción se repite k ciclos, la captura se verifica en cada ciclo y la recompensa se calcula por decisión. Reentrenada con la misma representación e hiperparámetros:
 - $k = 2$ (menos de 40 pasos = hasta 7.8 s): **99.5 % $\pm$ 0.5** en el servidor (100 % en el simulador);
 - $k = 3$: **96.0 % $\pm$ 1.4** en el servidor (98.0 % en el simulador).

Estas lecturas son hipótesis nuestras; la densidad triangular y los valores de k no están en el enunciado. Los resultados principales de este informe son los de la lectura implementada, y la aclaración del docente determina cuál corresponde.

6. Conclusiones

- **Formulación:** el MDP tiene una discretización justificada desde la física del servidor, con 41 estados y 164 valores Q .
- **Baseline:** Q-Learning tabular con ε decreciente es mejor y más estable que con ε constante (73.8 % frente a 70.0 % en el simulador).
- **Servidor real:** la política captura el 73.5 % (97.8 % bajo 30 m), con trayectorias que muestran el aprendizaje, sobre una infraestructura validada: simulador fiel, resets verificados y 0 errores de socket en 500 episodios.
- **Criterio de 90 %:** bajo la lectura 1 paso = 1 ciclo con d_0 uniforme no lo alcanza, y lo supera bajo lecturas alternativas del enunciado.

Para P2 proponemos:

- reemplazar la tabla por aproximadores continuos (DQN/PPO) sobre $(\hat{d}, \hat{\theta}, v)$, que permitan correcciones finas de rumbo a larga distancia;
- incorporar el giro de cuello para reducir la búsqueda inicial;
- estudiar un moldeado de recompensa consistente con el descuento.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.
- [4] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] F. Pardo, A. Tavakoli, V. Levdik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.