

Tareas Acotadas de RoboCup 2D con Métodos Tabulares: Persecución, Tiro a Puerta y Conducción

Fase 1 (P1)

Grupo N° 1

Integrantes:

Leonardo Candio — leonardo.candio@utec.edu.pe

Dimaël Rivas — dimael.rivas@utec.edu.pe

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos como MDP tabulares tres tareas del catálogo con la cinemática del *starter kit* y comparamos Q-Learning, SARSA y Monte Carlo first-visit, cada uno con ϵ constante y decreciente, en 5 semillas. **Persecución** (99 estados): 100 % de capturas con el reset del kit; en $[5, 40]$ m, 85.7 % frente a un óptimo exacto de 87.9 %, así que el 90 % no es alcanzable allí. **Tiro a puerta** (36 estados): 100 % sin arquero y 92.3 % con arquero, frente a un óptimo de 93.3 % para la misma representación. **Conducción** (36 estados): 97.7 % de avances de 30 m; la política greedy oscila por la agregación de estados, y con 245 estados llega al 100 %. Ningún método gana en todas las tareas: Monte Carlo con promedios aprende antes en el tiro (episodios de un paso); en la conducción Q-Learning aprende antes y SARSA es el más estable con ϵ constante; en la persecución el techo lo pone la representación. Verificamos la ejecución con `rcssserver`. La cooperación 2v1 queda formulada y en implementación.

1. Introducción

El catálogo propone cuatro tareas acotadas de RoboCup 2D. Implementamos tres y dejamos formulada la cuarta:

- **Persecución e intercepción:** capturar un balón inmóvil ($d \leq 0.8$ m) a $d_0 \in [5, 40]$ m; criterio: captura > 90 % en menos de 40 pasos.
- **Tiro a puerta:** elegir el tiro frente al arco, con o sin arquero; criterio: gol > 75 % sin arquero y > 50 % con arquero.
- **Conducción:** avanzar con el balón hacia el arco rival sin perderlo; criterio: avance > 30 m con control en > 80 % de los episodios.

Todas usan la cinemática del **starter kit** del curso: DASH y KICK desplazan una distancia exacta y TURN gira exactamente $\pm 35^\circ$, sin inercia ni ruido de movimiento y con observación completa. El simulador real [2, 3] es un POMDP más difícil; lo usamos para **verificar la ejecución** conectando el cliente Python a `rcssserver` en Docker (`docker compose up -d`), con un entrenador que resetea los episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

2.1. Persecución

Estados. El agente observa la distancia d al balón y su rumbo θ relativo al cuerpo: $s = (b_d(d), b_\theta(\theta))$, con 9 zonas de distancia y 11 sectores de rumbo ($|\mathcal{S}| = 99$, 396 valores Q ; Tabla 1), más un estado terminal de captura.

Componente	Bordes	Justificación
Rumbo b_θ	$\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$	La tolerancia angular de captura es $\arcsin(0.8/d)$: 4.6° a 10 m y 1.5° a 30 m, de ahí los sectores finos cerca del frente. 17.5° es la mitad del giro (el error máximo tras girar), 35° un giro y 90° separa delante/detrás.
Distancia b_d	3, 6, 10, 15, 20, 25, 30, 35 m	Con 1 m por paso, cada zona son 3–5 pasos de tiempo restante frente al presupuesto de 40; más finas cerca, donde se decide la maniobra final.

Tabla 1: Discretización de la persecución (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Acciones, transiciones y recompensa. $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$: DASH p avanza ℓ_p ($\ell_{100} = 1$ m, $\ell_{50} = 0.5$ m) en la dirección ϕ del cuerpo y TURN suma $\pm 35^\circ$ a ϕ . La dinámica es determinista sobre $(\mathbf{x}, \phi)$, pero $\mathcal{P}(s' | s, a)$ sobre los bins es estocástica: un TURN $+35$ lleva al frente un balón a 30° y no uno a 80° del mismo bin (aliasing; $\mathcal{S}$ no es un estado de Markov exacto). La recompensa es la del enunciado, $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$; con $\gamma = 1$ el primer término es telescópico y maximizar G_0 equivale a capturar en el menor número de pasos. Con $\gamma = 0.99$ el bono vale $100 \cdot 0.99^{39} = 67.6$ en el paso 39 (con $\gamma = 0.9$, solo 1.6). El episodio termina con la captura (sin bootstrap) o se trunca en $T_{max} = 40$, con bootstrap porque el tiempo no está en el estado [5].

2.2. Tiro a puerta, conducción y cooperación 2v1

La Tabla 2 resume las otras tres tareas, con la misma cinemática. Justificación:

- **Tiro.** Distancia y posición lateral determinan los ángulos a los postes ($\theta_{post_l}, \theta_{post_r}$) con menos estados. El error es *angular*: crece con la distancia real al punto apuntado, y desde un costado el arco se ve más angosto. El enunciado no fija σ , el alcance del arquero ni el riesgo de conducir p_{out} ; los fijamos *antes de entrenar* con una regla escrita sobre el óptimo exacto (el tiro óptimo debe depender del arquero, CONDUCIR debe ser óptimo en algún estado y el óptimo con arquero, $< 100\%$). La propuesta inicial ($p_{out} = 0.1$) falló la

segunda condición y la regla eligió $p_{out} = 0.02$. Aun así CONducIR es óptimo en un solo estado, por 0.25 puntos: la tarea es, en la práctica, de **una sola decisión**.

- **Conducción.** 0.8 m es el radio de posesión (el del KICK), 2 m un KICK y 4 m la pérdida. Quitamos d_g : en todo episodio queda entre ≈ 32 y ≈ 92 m y no cambia la mejor acción.
- **2v1.** Un bit indica si la línea de pase está bloqueada, que decide el riesgo de intercepción.

	Tiro a puerta	Conducción	Cooperación 2v1 (en implementación)
Inicio	Balón a $d_g \sim U[11, 25]$ m de la línea de gol, $y \sim U[-10, 10]$ m; arquero con prob. 0.5 en $y_k \sim U[-3, 3]$ m	Jugador en $x_0 \sim U[-40, -10]$, $y_0 \sim U[-20, 20]$ m, rumbo al azar; balón 0.5 m adelante	Zona de 30×20 m; compañero a 6–10 m y defensor a 4–8 m del poseedor
$\mathcal{S}$	d_g : 11–15, 15–20, 20–25 m; lateral: izq., centro ($ y \leq 3.5$), der.; arquero: sin, izq., centro, der. $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_b : ≤ 0.8 , (0.8, 2], (2, 4] m; θ_b : frente $\pm 17.5^\circ$, izq., der.; θ_g (al arco): frente, izq., der., atrás $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_{comp} , d_{def} , θ_{comp} , θ_{def} (3 bins c/u); línea bloqueada; centro/banda $ \mathcal{S} = 324$
$\mathcal{A}$	Tiro a $y^* \in \{-6, -3.5, 0, 3.5, 6\}$ m y CONducIR (+2 m, mínimo 11 m). $ \mathcal{A} = 6$	KICK 25 (balón +2 m si $d_b \leq 0.8$), DASH 80 (+0.8 m), TURN $\pm 35^\circ$. $ \mathcal{A} = 4$	PASE, DRIBLE, GIRAR, DESPEJE. $ \mathcal{A} = 4$
$\mathcal{P}$	Error angular $\epsilon \sim \mathcal{N}(0, (4^\circ)^2)$; afuera si $ y_c \geq 7.01$ m; atajado si $ y_c - y_k < 2$ m; con arquero, CONducIR es bloqueado con prob. 0.02	Determinista	Defensor a 0.6 m/paso con rumbo ruidoso; intercepción con prob. 0.8 si la línea está bloqueada; quite con prob. 0.5 si $d_{def} < 1$ m
$\mathcal{R}$	+100 gol, −30 afuera, −50 atajado o bloqueado; −0.2 por CONducIR	Δx del balón −0.1; −30 si $d_b > 4$ m o sale de la cancha; +50 al avanzar 30 m	+30 pase, −30 intercepción o quite, −10 fuera de la zona
γ, T_{max}	0.99; 10 (el tiro termina)	0.99; 100	0.99; 60
Criterio	Gol > 75 % sin y > 50 % con arquero	Avance de 30 m en > 80 %	Posesión > 50 pasos y ≥ 3 pases

Tabla 2: MDP de las otras tres tareas del catálogo, con la cinemática del kit.

3. Métodos y Protocolo Experimental

Comparamos cuatro reglas tabulares [1], con acciones ϵ -greedy, $Q_0 = 0$ y sin bootstrap en estados terminales: **Q-Learning** [4] (off-policy, $Q \leftarrow \alpha[r + \gamma \max_{a'} Q(s', a') - Q]$), **SARSA** (on-policy, con la acción a' realmente elegida), **MC first-visit con promedios** (paso $1/N$, el algoritmo del kit) y **MC first-visit con α constante** ($Q \leftarrow \alpha[G_t - Q]$). Exploración: $\epsilon = 0.1$ constante frente a ϵ geométrico decreciente de 1 a 0.1, que llega al piso al 60 % del presupuesto.

Protocolo. Dentro de cada tarea, los métodos comparten estados, acciones, presupuesto (80 000, 50 000 y 60 000 episodios en persecución, tiro y conducción), semillas 0–4 e inicios de evaluación. Periódicamente evaluamos la política greedy ($\epsilon = 0$, sin aprendizaje) en 500 inicios fijos con el mismo ruido para todas las condiciones. $\alpha \in \{0.03, 0.1, 0.3\}$ se eligió con un barrido en semillas 5–9: en el tiro solo con ϵ decreciente, en la conducción para cada exploración por separado, y en la persecución $\alpha = 0.1$ fijo. Reportamos la media de 5 semillas con IC 95 % bootstrap y declaramos una diferencia solo si los IC no se solapan. Cada cifra está guardada con su script, semilla y huella del código (notebooks 07, 10, 11 y 13).

4. Resultados

4.1. Persecución

Con la configuración del notebook del kit (MC, 3 500 episodios), nuestro entorno da $89.2 \% \pm 17.2$ (entre 44.8% y 100%) de éxito en 8 semillas: una sola semilla no es representativa. Como el kit es determinista, calculamos el mínimo exacto de pasos de cada inicio (A^* con heurística admisible, 1 000 inicios): con el reset del kit el óptimo captura el 100% en 18.6 pasos, y en $[5, 40]$ m **ninguna política supera el $87.9 \% \pm 1.0$** . La Tabla 3 resume la ablación de Q-Learning. La política (Figura 1) avanza con el balón entre -35° y $+17.5^\circ$ y gira hacia él fuera de esa ventana, más ancha que un giro, así que no oscila; las trayectorias greedy pasan de erráticas a casi rectas durante el entrenamiento (Figura 2).

Exploración	$d_0 \in [5, 40]$ m			Reset del kit	
	Final < 40	Episodios a 70 % / 80 %	≤ 40	Captura < 40	Pasos
ε decreciente	0.857 ± 0.003	12k / 12k–16k	0.876	1.000 ± 0.000	19.1
$\varepsilon = 0.1$ constante	0.843 ± 0.013	16k / 16k–32k	0.863	1.000 ± 0.000	19.3
<i>Óptimo exacto</i>	<i>0.879</i>			<i>1.000</i>	<i>18.6</i>

Tabla 3: Persecución: ablación de Q-Learning (R3, greedy, 5 semillas, media $\pm$ desv. est.).




Figura 1: Persecución: política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$, el mayor $Q(s, a)$ del estado (der.), aprendidos (estimaciones, no óptimos demostrados). Filas: distancia; columnas: rumbo relativo.




Figura 2: Persecución: trayectorias de la política greedy tras N episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

4.2. Tiro a puerta

Sin arquero, todas las condiciones superan el 98 % (óptimo: 100 %). Con arquero, el óptimo exacto es 95.2 % con el estado continuo y **93.3 %** con nuestros 36 estados (ruido muestral de una evaluación: 1.1 %); Q-Learning con ε decreciente llega al 92.3 % (Tabla 4, Figura 3), y las 8 condiciones cumplen el criterio en las 5 semillas. La política tira a ± 3.5 m, lejos del arquero, y coincide con el óptimo de la representación en 27 de 36 estados.

Tarea	Métrica	ε decreciente	$\varepsilon = 0.1$ constante	Referencia
Tiro, sin arquero	gol, final	100.0 [100.0, 100.0]	98.8 [98.1, 99.4]	óptimo 100
Tiro, con arquero	gol, final	92.3 [91.8, 92.6]	87.5 [85.6, 88.8]	óptimo repr. 93.3
Conducción	éxito, media últimas 5	97.7 [96.3, 99.0]	89.7 [83.8, 95.5]	guionado 100
Conducción	éxito, peor de últimas 5	94.2 [90.1, 97.2]	71.6 [59.4, 84.0]	

Tabla 4: Ablación de exploración de Q-Learning en tiro y conducción (% , media de 5 semillas [IC 95 %]). En negrita, las diferencias con IC separados.




Figura 3: Tiro a puerta, con arquero. (a) Ablación de exploración de Q-Learning; (b) los cuatro métodos con ε constante (Q-Learning queda bajo SARSA: sus curvas coinciden); media de 5 semillas, banda: mínimo–máximo. (c, d) Tiros greedy al inicio y al final del entrenamiento sobre 12 inicios (marca azul: arquero, que ataja a menos de 2 m).

4.3. Conducción

Un controlador guionado (en posesión, girar hacia el arco y patear; si no, girar hacia el balón y correr) logra el 100 % en 20 000 inicios (60.4 pasos en promedio, 85 como máximo), así que el 100 % es alcanzable. Q-Learning con ε decreciente llega al 97.7 % (media de las últimas 5 evaluaciones; Tabla 4). Aunque el entorno es determinista, **la política greedy oscila** (Figura 4a,b). Las caídas son timeouts: un ciclo $\text{TURN} +35/\text{TURN} -35$ entre dos estados agregados con valores casi empatados (41.87 frente a 42.00), que una actualización pequeña invierte. Con 245 estados (5 zonas de d_b y 7 sectores de rumbo para balón y arco) y el mismo presupuesto, Q-Learning y

SARSA quedan en 100 % en cada una de las últimas 5 evaluaciones de las 5 semillas (Figura 4c): **la oscilación viene de la agregación**, y 36 estados son pocos para esta tarea.




Figura 4: Conducción. (a) Ablación de exploración de Q-Learning (media de 5 semillas, banda: mínimo-máximo); (b) cada semilla con ϵ constante; (c) media (barra) y peor (marca) de las últimas 5 evaluaciones con 36 y 245 estados (120 000 episodios, ϵ decreciente); (d) política greedy final de Q-Learning en 6 inicios (verde: balón; gris: jugador; punteado: meta de 30 m).

Verificación en rcssserver. Ejecutamos la política final de la persecución en el servidor real, 200 episodios por distribución, con 0 comandos perdidos y 0 errores de reset: captura el 26.0 % $\pm$ 3.1 con el reset del kit (26.0 % en nuestro simulador con física del servidor) y el 20.5 % $\pm$ 2.9 en [5, 40] m (21.0 %). La verificación de tiro y conducción está en curso.

5. Comparación de Métodos

La Tabla 5 compara los cuatro métodos con ϵ decreciente.

Tarea	Q-Learning	SARSA	MC (promedios)	MC (α constante)
Persecución, [5, 40] m	84.7 (77.0)	85.3 (83.3)	85.3 (84.3)	45.8 (43.2)
Tiro, con arquero	92.2 (90.9)	92.2 (90.5)	92.8 (92.6)	91.8 (90.0)
Conducción, 36 estados	97.7 (92.4)	94.3 (76.2)	90.4 (70.8)	30.1 (22.3)

Tabla 5: Éxito greedy (%): media de las últimas 5 evaluaciones y, entre paréntesis, AUC (éxito medio durante el entrenamiento; mayor = aprende antes). Media de 5 semillas, ϵ decreciente. En negrita, el mejor de cada tarea y los que no se distinguen de él (IC 95 % solapados; los IC están en el notebook 13).

Por qué cada método rinde distinto en cada tarea. Solo damos como causa lo que un experimento aisló:

- **Persecución** (determinista, recompensa densa, sin riesgo): al final no hay diferencia entre Q-Learning, SARSA y MC con promedios; el techo lo pone la representación (óptimo

87.9 %). SARSA y MC aprenden antes; no aislamos por qué.

- **Tiro** (casi una decisión, resultado estocástico y terminal): Q-Learning y SARSA son idénticos por construcción, porque solo difieren al hacer bootstrap y el tiro termina el episodio. MC con promedios aprende antes y es el único que no se retrasa con ε constante (93.2 % frente a 86.0–86.6 %). Causa aislada: con $Q_0 = 0$ y valores reales de 70–100, un paso $\alpha = 0.03$ corrige lento las acciones poco visitadas ($\max_a Q$ subestima V^* en 6.6 puntos), mientras que el paso $1/N$ fija Q en el primer retorno y luego da la media muestral de un resultado estacionario; $\alpha = 0.1$, $Q_0 = 100$ o 4 veces más episodios cierran la brecha. El sesgo de maximización que predijimos para Q-Learning no apareció: el $\max$ casi no interviene, porque solo entra tras CONducir.
- **Conducción** (determinista, ~ 60 pasos, estados agregados): al final Q-Learning, SARSA y MC con promedios no se distinguen (el IC de MC es muy ancho, 79–99 %), pero **Q-Learning aprende mucho antes** (AUC 92.4 frente a 76.2 y 70.8): mientras ε es alto, SARSA y MC estiman el valor de una política casi aleatoria y Q-Learning, off-policy, ya aprende la greedy (con 245 estados está en 100 % desde la primera evaluación). Con ε constante SARSA es el más estable (96.8 frente a 89.7 %), aunque parte puede venir de α (0.03 frente a 0.1). Dos predicciones fallaron: no hay “acantilado” que haga a SARSA más prudente (los métodos TD pierden el balón en ≤ 0.5 % de los episodios de entrenamiento, y con radio de pérdida de 8 m nada cambia), y MC no resistió mejor la agregación [6]: con 36 estados congela su política en algunas semillas (64.5 % con 120 000 episodios) y con 245 llega a 97.8 %.
- **MC con α constante** falla en las dos tareas de episodios largos, también con 245 estados y α de hasta 0.003, y funciona en el tiro, de un paso. No aislamos la causa.

6. Discusión

Exploración. El efecto de ε decreciente depende de la tarea y de α . En la persecución aprende antes (70 % en 12 000 episodios frente a 16 000) y termina algo más alto. En el tiro termina más alto con $\alpha = 0.03$, pero es solo velocidad: la brecha desaparece con $\alpha = 0.1$, $Q_0 = 100$ o más episodios, y elegir α solo con ε decreciente favoreció a este en la comparación. En la conducción, con α elegido para cada exploración, termina mejor en Q-Learning, aunque ε constante aprende antes (su retorno de entrenamiento se estabiliza en ≈ 3 000 episodios frente a ≈ 35 000); en SARSA no hay diferencia final.

Discretización. Fue el factor que más pesó. En la persecución, la discretización del kit (20 estados) llega al 56.6 %, nuestra primera versión (20) al 61.0 %, R3 (99) al 84.7 % y R4 (150) cae al 81.0 % por falta de datos; en la conducción, pasar de 36 a 245 estados elimina la oscilación.

¿Por qué no mejores resultados en la persecución? En [5, 40] m: (i) 40 pasos no alcanzan para los inicios lejanos (el óptimo captura el 18.7 % a 35–40 m), así que el 90 % no es alcanzable con ningún algoritmo; (ii) la tabla deja una brecha pequeña con el óptimo, a 30–40 m; (iii) la física del kit no es la del servidor (aceleración gradual, giros que dependen de la velocidad, ruido, visión parcial), por eso transfiere mal. Una política entrenada con la física del servidor alcanza el $73.5 \% \pm 3.1$ en vivo, sin errores de socket en 500 episodios consecutivos.

7. Conclusiones

- **Criterios:** persecución, 100 % con el reset del kit (en [5, 40] m el 90 % no es alcanzable: óptimo 87.9 %, nuestro 85.7 %); tiro, 100 % sin arquero y 92.3 % con arquero (óptimo de la representación: 93.3 %); conducción, 97.7 % (100 % con 245 estados).
- **Modelado:** las cotas exactas o constructivas separan los límites de la tarea de los del aprendizaje; la representación pesó más que el algoritmo.
- **Métodos:** ninguno gana en todas las tareas. MC con promedios fue el mejor en el tiro (un paso, resultado estocástico); en la conducción Q-Learning aprendió antes y SARSA fue el más estable con ε constante; MC con α constante falló en las dos tareas de episodios largos. Son resultados de tres tareas, no reglas generales. ε decreciente nunca terminó peor de forma detectable, pero su ventaja depende de α .
- **Pendiente para P1:** cooperación 2v1 y la verificación en `rcssserver` de tiro y conducción. Para P2: aproximadores continuos (DQN/PPO), que evitan elegir a mano la agregación, y entrenar con la física del servidor.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [4] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [5] F. Pardo, A. Tavakoli, V. Levdik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.
- [6] S. P. Singh, T. Jaakkola, and M. I. Jordan, “Learning without state-estimation in partially observable Markovian decision processes,” in *ICML*, 1994, pp. 284–292.