

Tareas Acotadas de RoboCup 2D con Métodos Tabulares: Persecución, Tiro, Conducción y Cooperación 2v1

Fase 1 (P1)

Grupo N° 1

Integrantes:

Leonardo Candio — leonardo.candio@utec.edu.pe

Dimael Rivas — dimael.rivas@utec.edu.pe

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos como MDP tabulares las cuatro tareas del catálogo con la cinemática del *starter kit* y comparamos Q-Learning, SARSA y Monte Carlo first-visit, con ε constante y decreciente, en 5 semillas. **Persecución:** 100 % de capturas con el reset del kit; en $[5, 40]$ m, 85.7 % frente a un óptimo exacto de 87.9 %, así que el 90 % no es alcanzable allí. **Tiro:** 100 % sin arquero y 92.3 % con arquero (óptimo de la representación: 93.3 %). **Conducción:** 97.7 %; la política oscila por la agregación de estados y con 245 estados llega al 100 %. **2v1:** 65 % frente al 11 % de una heurística. Ningún método gana en todas: MC con promedios aprende antes en el tiro y falla en la 2v1; Q-Learning es el mejor en la 2v1 y el más rápido en la conducción. Verificamos la ejecución con `rcssserver`.

1. Introducción

El catálogo propone cuatro tareas acotadas de RoboCup 2D y las implementamos todas: **persecución** (capturar un balón inmóvil, $d \leq 0.8$ m, a $d_0 \in [5, 40]$ m; criterio: captura > 90 % en menos de 40 pasos), **tiro a puerta**, **conducción** y **cooperación 2v1** (criterios en la Tabla 2). Todas usan la cinemática del **starter kit** del curso: DASH y KICK desplazan una distancia exacta y TURN gira exactamente $\pm 35^\circ$, sin inercia ni ruido de movimiento y con observación completa. El simulador real [2, 3] es un POMDP más difícil; lo usamos para **verificar la ejecución** conectando el cliente Python a `rcssserver` en Docker (`docker compose up -d`), con un entrenador que resetea los episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

2.1. Persecución

Estados. El agente observa la distancia d al balón y su rumbo θ relativo al cuerpo: $s = (b_d(d), b_\theta(\theta))$, con 9 zonas de distancia y 11 sectores de rumbo ($|\mathcal{S}| = 99$, 396 valores Q ; Tabla 1), más un estado terminal de captura.

Componente	Bordes	Justificación
Rumbo b_θ	$\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$	La tolerancia angular de captura es $\arcsin(0.8/d)$: 4.6° a 10 m y 1.5° a 30 m, de ahí los sectores finos cerca del frente. 17.5° es la mitad del giro (el error máximo tras girar), 35° un giro y 90° separa delante/detrás.
Distancia b_d	3, 6, 10, 15, 20, 25, 30, 35 m	Con 1 m por paso, cada zona son 3–5 pasos de tiempo restante frente al presupuesto de 40; más finas cerca, donde se decide la maniobra final.

Tabla 1: Discretización de la persecución (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Acciones, transiciones y recompensa. $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } \pm 35\}$: DASH avanza 1 o 0.5 m en la dirección del cuerpo y TURN suma $\pm 35^\circ$. La dinámica es determinista sobre $(\mathbf{x}, \phi)$, pero sobre los bins $\mathcal{P}(s' | s, a)$ es estocástica: un TURN +35 lleva al frente un balón a 30° y no uno a 80° del mismo bin (aliasing). Recompensa del enunciado: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$; con $\gamma = 1$ el primer término es telescópico y maximizar G_0 equivale a capturar en menos pasos. Con $\gamma = 0.99$ el bono vale 67.6 en el paso 39 (con $\gamma = 0.9$, solo 1.6). El episodio termina con la captura o se trunca en $T_{max} = 40$, con bootstrap porque el tiempo no está en el estado [5].

2.2. Tiro a puerta, conducción y cooperación 2v1

La Tabla 2 resume las otras tres tareas, con la misma cinemática. Justificación:

- **Tiro.** Distancia y posición lateral determinan los ángulos a los postes con menos estados. El error es *angular*, así que crece con la distancia real al punto apuntado. σ , el alcance del arquero y p_{out} no están en el enunciado: los fijamos *antes de entrenar* con una regla escrita sobre el óptimo exacto (el tiro óptimo debe depender del arquero, CONDUCIR debe ser óptimo en algún estado y el óptimo con arquero, $< 100\%$); la regla cambió p_{out} de 0.1 a 0.02. Aun así CONDUCIR es óptimo en un solo estado, por 0.25 puntos: la tarea es, en la práctica, de **una sola decisión**.
- **Conducción.** 0.8 m es el radio de posesión (el del KICK), 2 m un KICK y 4 m la pérdida. Quitamos d_g : en todo episodio queda entre ≈ 32 y ≈ 92 m y no cambia la mejor acción.
- **2v1.** El agente controla al atacante con el balón; compañero y defensor son guionados. Un bit indica si la línea de pase está bloqueada, que decide el riesgo de intercepción. GIRAR se aleja del defensor; si ya está casi detrás, gira hacia el centro (si no, alternaba de lado sin fin).

	Tiro a puerta	Conducción	Cooperación 2v1
Inicio	Balón a $d_g \sim U[11, 25]$ m de la línea de gol, $y \sim U[-10, 10]$ m; arquero con prob. 0.5 en $y_k \sim U[-3, 3]$ m	Jugador en $x_0 \sim U[-40, -10]$, $y_0 \sim U[-20, 20]$ m, rumbo al azar; balón 0.5 m adelante	Zona de 30×20 m; compañero a 6–10 m y defensor a 4–8 m del poseedor
$\mathcal{S}$	d_g : 11–15, 15–20, 20–25 m; lateral: izq., centro ($ y \leq 3.5$), der.; arquero: sin, izq., centro, der. $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_b : ≤ 0.8 , (0.8, 2], (2, 4] m; θ_b : frente $\pm 17.5^\circ$, izq., der.; θ_g (al arco): frente, izq., der., atrás $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_{comp} , d_{def} , θ_{comp} , θ_{def} (3 bins c/u); línea bloqueada; centro/banda $ \mathcal{S} = 324$
$\mathcal{A}$	Tiro a $y^* \in \{-6, -3.5, 0, 3.5, 6\}$ m y CONDUCCIÓN (+2 m, mínimo 11 m). $ \mathcal{A} = 6$	KICK 25 (balón +2 m si $d_b \leq 0.8$), DASH 80 (+0.8 m), TURN $\pm 35^\circ$. $ \mathcal{A} = 4$	PASE, DRIBLE (+1 m), GIRAR (35°), DESPEJE (fin, 0). $ \mathcal{A} = 4$
$\mathcal{P}$	Error angular $\epsilon \sim \mathcal{N}(0, (4^\circ)^2)$; afuera si $ y_c \geq 7.01$ m; atajado si $ y_c - y_k < 2$ m; con arquero, CONDUCCIÓN es bloqueado con prob. 0.02	Determinista	Defensor a 0.6 m/paso hacia el poseedor, rumbo con ruido $\mathcal{N}(0, 15^\circ)$; compañero a 0.6 m/paso hacia un punto de apoyo; intercepción con prob. 0.8 si la línea está bloqueada; quite con prob. 0.5 si $d_{def} < 1$ m
$\mathcal{R}$	+100 gol, -30 afuera, -50 atajado o bloqueado; -0.2 por CONDUCCIÓN	Δx del balón -0.1; -30 si $d_b > 4$ m o sale de la cancha; +50 al avanzar 30 m	+30 pase, -30 intercepción o quite, -10 fuera de la zona
γ, T_{max}	0.99; 10 (el tiro termina)	0.99; 100	0.99; 60
Criterio	Gol > 75 % sin y > 50 % con arquero	Avance de 30 m en > 80 %	Posesión > 50 pasos y ≥ 3 pases

Tabla 2: MDP de las otras tres tareas del catálogo, con la cinemática del kit.

3. Métodos y Protocolo Experimental

Comparamos cuatro reglas tabulares [1], con acciones ε -greedy, $Q_0 = 0$ y sin bootstrap en estados terminales: **Q-Learning** [4] (off-policy, $Q \leftarrow \alpha[r + \gamma \max_{a'} Q(s', a') - Q]$), **SARSA** (on-policy, con la acción a' realmente elegida), **MC first-visit con promedios** (paso $1/N$, el algoritmo del kit) y **MC first-visit con α constante** ($Q \leftarrow \alpha[G_t - Q]$). Exploración: $\varepsilon = 0.1$ constante frente a ε geométrico decreciente de 1 a 0.1, que llega al piso al 60 % del presupuesto.

Protocolo. Dentro de cada tarea, los métodos comparten estados, acciones, presupuesto (80 000, 50 000, 60 000 y 60 000 episodios en persecución, tiro, conducción y 2v1), semillas 0–4 e inicios de evaluación. Periódicamente evaluamos la política greedy ($\varepsilon = 0$, sin aprendizaje) en 500 inicios fijos con el mismo ruido para todas las condiciones. $\alpha \in \{0.03, 0.1, 0.3\}$ se eligió con un barrido en semillas 5–9: en el tiro solo con ε decreciente, en conducción y 2v1 para cada exploración por separado, y en la persecución $\alpha = 0.1$ fijo. Reportamos la media de 5 semillas con IC 95 % bootstrap y declaramos una diferencia solo si los IC no se solapan. Cada cifra está guardada con su script, semilla y huella del código (notebooks 07, 10, 11 y 13).

4. Resultados

4.1. Persecución

Con la configuración del notebook del kit (MC, 3 500 episodios), nuestro entorno da $89.2 \% \pm 17.2$ (entre 44.8 % y 100 %) de éxito en 8 semillas: una sola semilla no es representativa. Como el kit es determinista, calculamos el mínimo exacto de pasos de cada inicio (A^* con heurística admisible, 1 000 inicios): con el reset del kit el óptimo captura el 100 % en 18.6 pasos, y en

[5, 40] m **ninguna política supera el 87.9 % $\pm$ 1.0**. La Tabla 3 resume la ablación de Q-Learning. La política (Figura 1) avanza con el balón entre -35° y $+17.5^\circ$ y gira hacia él fuera de esa ventana, más ancha que un giro, así que no oscila; las trayectorias greedy pasan de erráticas a casi rectas durante el entrenamiento (Figura 2).

Exploración	$d_0 \in [5, 40]$ m			Reset del kit	
	Final < 40	Episodios a 70 % / 80 %	≤ 40	Captura < 40	Pasos
ε decreciente	0.857 ± 0.003	12k / 12k–16k	0.876	1.000 ± 0.000	19.1
$\varepsilon = 0.1$ constante	0.843 ± 0.013	16k / 16k–32k	0.863	1.000 ± 0.000	19.3
<i>Óptimo exacto</i>	<i>0.879</i>			<i>1.000</i>	<i>18.6</i>

Tabla 3: Persecución: ablación de Q-Learning (R3, greedy, 5 semillas, media $\pm$ desv. est.).




Figura 1: Persecución: política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$, el mayor $Q(s, a)$ del estado (der.), aprendidos (estimaciones, no óptimos demostrados). Filas: distancia; columnas: rumbo relativo.




Figura 2: Persecución: trayectorias de la política greedy tras N episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

4.2. Tiro a puerta

Sin arquero, todas las condiciones superan el 98 % (óptimo: 100 %). Con arquero, el óptimo exacto es 95.2 % con el estado continuo y **93.3 %** con nuestros 36 estados (ruido muestral de una evaluación: 1.1 %); Q-Learning con ε decreciente llega al 92.3 % (Tabla 4, Figura 3), y las 8 condiciones cumplen el criterio en las 5 semillas. La política tira a ± 3.5 m, lejos del arquero, y coincide con el óptimo de la representación en 27 de 36 estados.

4.3. Conducción

Un controlador guionado (en posesión, girar hacia el arco y patear; si no, girar hacia el balón y correr) logra el 100 % en 20 000 inicios (60.4 pasos en promedio, 85 como máximo), así que el

Tarea	Métrica	ε decreciente	$\varepsilon = 0.1$ constante	Referencia
Tiro, sin arquero	gol, final	100.0 [100.0, 100.0]	98.8 [98.1, 99.4]	óptimo 100
Tiro, con arquero	gol, final	92.3 [91.8, 92.6]	87.5 [85.6, 88.8]	óptimo repr. 93.3
Conducción	éxito, media últimas 5	97.7 [96.3, 99.0]	89.7 [83.8, 95.5]	guionado 100
Conducción	éxito, peor de últimas 5	94.2 [90.1, 97.2]	71.6 [59.4, 84.0]	
2v1	éxito, media últimas 5	64.8 [61.3, 68.1]	65.5 [64.2, 67.4]	heurística 10.8

Tabla 4: Ablación de exploración de Q-Learning en tiro, conducción y 2v1 (% , media de 5 semillas [IC 95 %]). En negrita, las diferencias con IC separados.




Figura 3: Tiro a puerta, con arquero. (a) Ablación de exploración de Q-Learning; (b) los cuatro métodos con ε constante (Q-Learning queda bajo SARSA: sus curvas coinciden); media de 5 semillas, banda: mínimo-máximo. (c, d) Tiros greedy al inicio y al final del entrenamiento sobre 12 inicios (marca azul: arquero, que ataja a menos de 2 m).

100 % es alcanzable. Q-Learning con ε decreciente llega al 97.7 % (media de las últimas 5 evaluaciones; Tabla 4). Aunque el entorno es determinista, **la política greedy oscila** (Figura 4a,b). Las caídas son timeouts: un ciclo $\text{TURN} +35/\text{TURN} -35$ entre dos estados agregados con valores casi empatados (41.87 frente a 42.00), que una actualización pequeña invierte. Con 245 estados (5 zonas de d_b y 7 sectores de rumbo para balón y arco) y el mismo presupuesto, Q-Learning y SARSA quedan en 100 % en cada una de las últimas 5 evaluaciones de las 5 semillas (Figura 4c): **la oscilación viene de la agregación**, y 36 estados son pocos para esta tarea.

4.4. Cooperación 2v1

No hay cota exacta (estado continuo y estocástico). Como referencia, una heurística (pasar con la línea libre; si no, alejarse del defensor) cumple el criterio en el 10.8 % de los episodios, casi siempre por quites. Q-Learning llega al 64.8 % con ε decreciente y al 65.5 % con constante (Tabla 4, Figura 5). Nunca pasa con la línea bloqueada (intercepciones ≈ 0), y sus fallas son quites y salidas de la zona (Figura 5d). La recompensa invita a pasar mucho (≈ 20 pases por episodio). Una representación más fina (1944 estados, con el rumbo al centro de la zona) rinde *peor* con el mismo presupuesto (62.4 frente a 67.9 %) y no reduce las salidas: la información faltante no es lo que limita, aunque no podemos separarlo de “más estados que datos”.




Figura 4: Conducción. (a) Ablación de exploración de Q-Learning (media de 5 semillas, banda: mínimo–máximo); (b) cada semilla con ϵ constante; (c) media (barra) y peor (marca) de las últimas 5 evaluaciones con 36 y 245 estados (120 000 episodios, ϵ decreciente); (d) política greedy final de Q-Learning en 6 inicios (verde: balón; gris: jugador; punteado: meta de 30 m).




Figura 5: Cooperación 2v1. (a) Ablación de exploración de Q-Learning; (b) los cuatro métodos con ϵ decreciente (media de 5 semillas, banda: mínimo–máximo; línea: heurística); (c) media (barra) y peor (marca) de las últimas 5 evaluaciones con 324 y 1 944 estados (120 000 episodios); (d) cómo terminan los 500 episodios de evaluación con la política greedy final y con la heurística.

Verificación en rcssserver. Ejecutamos cada política greedy en el servidor real, con 0 ciclos perdidos en todas las corridas. El estado de las tareas nuevas se calcula con la verdad de terreno del entrenador (observación completa, como en su MDP); es una verificación de ejecución, no de transferencia. **Persecución** (con la percepción del jugador): captura el 26.0 % $\pm$ 3.1 con el reset del kit. **Tiro:** 20/20 goles sin arquero y 20/20 con un arquero quieto (que solo bloquea con el cuerpo); el error angular medido es de 1.75° frente a los 4° del modelo. **Conducción:** 10/10 avances de 30 m, aunque un KICK 25 real deja rodar el balón $\approx$ 13.6 m, no 2 m. **2v1:** 0/10; un pase real tarda varios ciclos (en el modelo es instantáneo) y el balón sale de la zona (7) o lo gana el defensor (3).

5. Comparación de Métodos

Tarea	Q-Learning	SARSA	MC (promedios)	MC (α constante)
Persecución, [5, 40] m	84.7 (77.0)	85.3 (83.3)	85.3 (84.3)	45.8 (43.2)
Tiro, con arquero	92.2 (90.9)	92.2 (90.5)	92.8 (92.6)	91.8 (90.0)
Conducción, 36 estados	97.7 (92.4)	94.3 (76.2)	90.4 (70.8)	30.1 (22.3)
Cooperación 2v1	64.8 (44.9)	54.2 (28.2)	7.8 (2.6)	20.7 (9.2)

Tabla 5: Éxito greedy (%): media de las últimas 5 evaluaciones y, entre paréntesis, AUC (éxito medio durante el entrenamiento; mayor = aprende antes). Media de 5 semillas, ε decreciente. En negrita, el mejor de cada tarea y los que no se distinguen de él (IC 95 % solapados; los IC están en el notebook 13).

Por qué cada método rinde distinto en cada tarea. Solo damos como causa lo que un experimento aisló:

- **Persecución** (determinista, recompensa densa, sin riesgo): al final no hay diferencia; el techo lo pone la representación (óptimo 87.9 %). SARSA y MC aprenden antes; no aislamos por qué.
- **Tiro** (casi una decisión, resultado estocástico y terminal): Q-Learning y SARSA son idénticos por construcción (solo difieren al hacer bootstrap, y los tiros son terminales). MC con promedios aprende antes y es el único que no se retrasa con ε constante (93.2 frente a 86.0–86.6 %). Causa aislada: con $Q_0 = 0$ y valores de 70–100, un paso $\alpha = 0.03$ corrige lento las acciones poco visitadas ($\max_a Q$ subestima V^* en 6.6 puntos), mientras que $1/N$ fija Q en el primer retorno; $\alpha = 0.1$, $Q_0 = 100$ o 4 veces más episodios cierran la brecha. El sesgo de maximización que predijimos no apareció: el máx solo entra tras CONDUCIR.
- **Conducción** (determinista, ~ 60 pasos, estados agregados): al final no se distinguen Q-Learning, SARSA y MC con promedios (IC de MC: 79–99 %), pero **Q-Learning aprende mucho antes** (AUC 92.4 frente a 76.2 y 70.8): con ε alto, SARSA y MC estiman el valor de una política casi aleatoria, mientras que Q-Learning, off-policy, ya aprende la greedy. Con ε constante SARSA es el más estable (96.8 frente a 89.7 %; parte puede venir de α). No hubo “acantilado” (pérdidas ≤ 0.5 % al explorar, y un radio de 8 m no cambia nada), y MC no resistió mejor la agregación [6]: con 36 estados congela su política en algunas semillas.
- **2v1** (estocástica, 60 pasos, riesgo real): Q-Learning es el mejor y aprende antes; SARSA queda ≈ 11 puntos atrás. Aun con riesgo real, SARSA no fue más prudente: al explorar sufre *más* quites (13.8 frente a 8.7 %), y la diferencia no crece con la probabilidad de quite (0.2, 0.5, 0.8).
- **MC** falla en los episodios largos: con α constante en persecución, conducción y 2v1 (aun con 245 estados y $\alpha = 0.003$), y con promedios en la 2v1, donde el 75 % de sus episodios greedy terminan en DESPEJE. Solo funciona bien en el tiro. No aislamos la causa.

6. Discusión

Exploración. El efecto de ε decreciente depende de la tarea y de α (Tabla 4): termina algo más alto en la persecución y mejor en la conducción (Q-Learning); en el tiro también, pero es solo velocidad (la brecha desaparece con $\alpha = 0.1$, $Q_0 = 100$ o más episodios); en la 2v1 no hay diferencia final. ε constante estabiliza antes el retorno de entrenamiento en la conducción y aprende antes en la 2v1 (AUC 58.8 frente a 44.9 %).

Discretización. Fue el factor que más pesó. En la persecución, la discretización del kit (20 estados) llega al 56.6 %, R3 (99) al 84.7 % y R4 (150) cae al 81.0 % por falta de datos; en la conducción, pasar de 36 a 245 estados elimina la oscilación; en la 2v1, pasar de 324 a 1944 empeora con el mismo presupuesto.

¿Por qué no mejores resultados en la persecución? En [5, 40] m, 40 pasos no alcanzan para los inicios lejanos (el óptimo captura el 18.7 % a 35–40 m), así que el 90 % no es alcanzable con ningún algoritmo; la tabla deja además una brecha pequeña a 30–40 m. En el servidor la física es otra (aceleración gradual, giros que dependen de la velocidad, ruido): una política entrenada con esa física alcanza el 73.5 % $\pm$ 3.1 en vivo, sin errores de socket en 500 episodios.

7. Conclusiones

- **Criterios:** persecución, 100 % con el reset del kit (en [5, 40] m el óptimo es 87.9 % y llegamos a 85.7 %); tiro, 100 % sin arquero y 92.3 % con arquero; conducción, 97.7 % (100 % con 245 estados); 2v1, 65 % (heurística: 11 %).
- **Métodos:** ninguno gana en todas las tareas, y la representación pesó más que el algoritmo. MC con promedios fue el mejor en el tiro (un paso); Q-Learning, en la 2v1 y el más rápido en la conducción; MC con α constante falló en los episodios largos, y MC con promedios en la 2v1. ε decreciente nunca terminó peor de forma detectable, pero su ventaja depende de α . Son resultados de cuatro tareas, no reglas generales.
- **Servidor real:** ejecución verificada en las cuatro tareas; las políticas de tiro y conducción funcionan allí, las de persecución y 2v1 no. Para P2: aproximadores continuos (DQN/PPO) y entrenar con la física del servidor.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [4] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [5] F. Pardo, A. Tavakoli, V. Levdik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.
- [6] S. P. Singh, T. Jaakkola, and M. I. Jordan, “Learning without state-estimation in partially observable Markovian decision processes,” in *ICML*, 1994, pp. 284–292.