

Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

Fase 1 (P1)

Grupo N° [completar]

Integrantes:

Estudiante 1 (código) — Correo institucional

Estudiante 2 (código) — Correo institucional

Estudiante 3 (código) — Correo institucional

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos la tarea de persecución de balón como un MDP tabular de 20 estados (distancia y rumbo del balón) y 4 macro-acciones, sobre el entorno cinemático del *starter kit* del curso. Entrenamos Q-Learning con distancias iniciales en todo el rango del enunciado, $d_0 \in [5, 40]$ m. La exploración ε decreciente ($1.0 \rightarrow 0.1$) aprende unas tres veces más rápido y es más estable que $\varepsilon = 0.1$ constante ($61.0 \% \pm 0.8$ frente a $58.1 \% \pm 3.8$ en el rango completo). Con el reset del kit ($d_0 \approx 11\text{--}19$ m), la política captura el **99.6 %** en menos de 40 pasos en las 5 semillas, con 24.2 pasos en promedio y retorno $G_0 \approx 110$. Validamos la transferencia conectando el cliente a `rcssserver`: con física real la misma política captura el $26.0 \% \pm 3.1$ con el reset del kit. Como extensión, una política entrenada con la física del servidor alcanza el 73.5 % en el rango completo.

1. Introducción y Descripción de la Tarea

Elegimos la tarea acotada de **persecución e intercepción de balón**: el jugador parte de una posición y orientación arbitrarias, con el balón inmóvil a $d_0 \in [5, 40]$ m, y debe capturarlo ($d \leq 0.8$ m) en el menor tiempo posible. El criterio de éxito es una tasa de captura $> 90 \%$ en menos de 40 pasos.

Como P1 consiste en tareas acotadas, usamos como **entorno principal el del starter kit** entregado por el profesor (`agente_cero_mc_control_persecucion.ipynb`), reimplementado fielmente en `src/kit_env.py`:

- DASH 100 avanza exactamente 1.0 m y DASH 50, 0.5 m;
- TURN ± 35 gira exactamente $\pm 35^\circ$;

- no hay inercia ni ruido, y el agente observa la distancia y el rumbo verdaderos.

Evaluamos con dos distribuciones de inicio:

- **[5, 40] m:** d_0 uniforme sobre el rango del enunciado, con posición y orientación arbitrarias. Se usa para entrenar y para la evaluación periódica.
- **Reset del kit:** jugador cerca de $(-15, 0)$ y balón cerca del centro, así que $d_0 \approx 11\text{--}19\text{ m}$.

El simulador real [2, 4] es un POMDP más difícil: inercia, giros que dependen de la velocidad, ruido y visión parcial. Lo usamos para **validar la transferencia**, conectando el cliente Python a `rcssserver` (Docker, `docker compose up -d`). El servidor corre controlado por un entrenador (coach offline), que resetea los episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

Espacio de estados ($\mathcal{S}$). El agente observa (d, θ) : la distancia al balón y su rumbo relativo al cuerpo. El estado es $s = (b_d(d), b_\theta(\theta))$, más un estado terminal de captura sin entradas en Q . Hay $|\mathcal{S}| = 4 \times 5 = 20$ estados no terminales y la tabla Q tiene $20 \times 4 = 80$ valores. La implementación reserva además un estado de balón no adquirido, que en el kit nunca se visita porque la observación es completa. La Tabla 1 justifica cada borde a partir de la cinemática.

Componente	Bordes	Justificación
Distancia b_d	3, 10, 20 m	Con 1 m por paso, la distancia es aproximadamente el número de pasos restantes: 10 y 20 m separan regímenes de tiempo frente al presupuesto de 40. Bajo 3 m la geometría de la aproximación final domina.
Rumbo b_θ	$\pm 17.5^\circ, \pm 90^\circ$	Los giros son exactamente de 35° , así que el rumbo alcanzable está en una red de paso 35° y siempre puede dejarse el balón dentro de $\pm 17.5^\circ$. Con $\pm 90^\circ$ se separa delante/detrás: detrás, avanzar aleja. Detrás se distingue el lado para saber hacia dónde girar.

Tabla 1: Discretización del estado. Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Espacio de acciones ($\mathcal{A}$). $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$. En el kit, con posición $\mathbf{x}$ y rumbo ϕ : DASH p : $\mathbf{x} += \ell_p(\cos \phi, \sin \phi)$ con $\ell_{100} = 1\text{ m}$ y $\ell_{50} = 0.5\text{ m}$; TURN ± 35 : $\phi += \pm 35^\circ$.

Transiciones ($\mathcal{P}$). Sobre el estado continuo $(\mathbf{x}, \phi)$ la dinámica es determinista. Sobre los bins, $\mathcal{P}(s' | s, a)$ es estocástica porque el estado no conserva la posición exacta dentro del bin. Un TURN $+35$ lleva al frente un balón a 30° , pero no uno a 80° , aunque ambos estén en el mismo bin. Es aliasing de estados; $\mathcal{S}$ es una aproximación, no un estado de Markov exacto.

Recompensa ($\mathcal{R}$). La del enunciado: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$. Con $\gamma = 1$ el término de aproximación es telescópico: $G_0 = (d_0 - d_T) - 0.2T + 100 \cdot \mathbb{I}\{\text{captura}\}$. Con captura, d_T es casi constante, así que maximizar G_0 equivale a capturar en el menor número de pasos. El moldeado basado en potencial con $\Phi = -d$ sería $d_t - \gamma d_{t+1}$ [3]. Con $\gamma < 1$ no afirmamos invariancia de la política.

Descuento y horizonte. $\gamma = 0.99$: el bono de captura vale $100 \cdot 0.99^{39} = 67.6$ en el paso 39; con $\gamma = 0.9$ valdría solo 1.6. El episodio termina con la captura (sin bootstrap) o se trunca en $T_{max} = 40$ pasos. En el truncamiento se hace bootstrap desde s' , porque el tiempo no forma parte del estado [6].

3. Algoritmo de Aprendizaje por Refuerzo

Q-Learning [5, 1]: $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$, sin bootstrap en estados terminales, con acciones ε -greedy y desempate al azar. Comparamos dos exploraciones con el mismo nivel final:

- $\varepsilon = 0.1$ constante;
- $\varepsilon_k = \max(0.1, 1.0 \cdot d^k)$ con $d = 0.999808$, que llega al mínimo al 60 % del presupuesto.

Hiperparámetros. $\alpha = 0.03$, $\gamma = 0.99$, 20 000 episodios por corrida y 5 semillas por condición. Cada 1 000 episodios evaluamos la política greedy ($\varepsilon = 0$, sin aprendizaje) sobre 500 inicios fijos en [5, 40] m. Al final, evaluamos la Q-table también sobre 500 inicios del reset del kit. Guardamos la Q-table, el historial y la configuración de cada corrida.

Selección. Con la misma representación y las mismas condiciones probamos también SARSA y Monte Carlo first-visit (el algoritmo del kit). MC obtuvo la mejor media en [5, 40] m (65.5 % frente a 61.0 %), pero con más varianza. Q-Learning fue el único que superó el 90 % con el reset del kit en las 5 semillas; SARSA lo hizo en 4 de 5 y MC en 2 de 5. Por eso reportamos Q-Learning.

4. Resultados Experimentales y Análisis

Fidelidad al kit. Con la configuración del notebook del kit (MC first-visit, 3 500 episodios, $\varepsilon = \max(0.05, 0.998^k)$, su discretización y su reset), nuestro entorno da $89.2 \% \pm 17.2$ (entre 44.8 % y 100 %) de éxito greedy en 8 semillas. Un resultado de una sola semilla, como el 100 % de la semilla 42 del código original, no es representativo; por eso reportamos siempre 5 semillas.

Ablación de la exploración. La Tabla 2 y la Figura 1 resumen la ablación.

Exploración	$d_0 \in [5, 40]$ m			Reset del kit	
	Últimas 5	Peor	Episodios hasta 55 %	Captura < 40	Pasos
ε decreciente	0.610 $\pm$ 0.008	0.576	2k–3k (5/5)	0.996 $\pm$ 0.000	24.2
$\varepsilon = 0.1$ constante	0.581 $\pm$ 0.038	0.466	8k–9k (4/5)	0.996 $\pm$ 0.000	24.3

Tabla 2: Ablación en el entorno del kit (Q-Learning, greedy, 5 semillas). “Últimas 5”: media de las 5 últimas evaluaciones; “Peor”: la peor de ellas en cualquier semilla. En [5, 40] m, $G_0 = 76.6$ con 30.7 pasos (decreciente) y $G_0 = 72.6$ con 30.9 pasos (constante); con el reset del kit, $G_0 \approx 110$.

Política, valor y trayectorias. La Figura 3 muestra $\hat{\pi}(s)$ y $\hat{V}(s) = \max_a Q(s, a)$; son estimaciones aprendidas, no óptimos demostrados. La política gira hacia el balón y avanza cuando lo




Figura 1: Evaluación greedy durante el entrenamiento sobre 500 inicios fijos en $[5, 40]$ m (media $\pm$ desv. est. en 5 semillas).




Figura 2: Retorno G_0 y tasa de éxito de los episodios de entrenamiento (con exploración), media móvil de 500 episodios. La condición decreciente parte más baja porque explora casi al azar al inicio.

tiene de frente. La Figura 4 muestra la política greedy guardada a lo largo del entrenamiento: las trayectorias pasan de erráticas a casi rectas.




Figura 3: Política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$ (der.) aprendidos en el entorno del kit. Filas: distancia; columnas: rumbo relativo.




Figura 4: Trayectorias 2D de la política greedy tras N episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

Transferencia a rcssserver. Ejecutamos la política del kit en el servidor real, 200 episodios por distribución, con 0 comandos perdidos y 0 errores de reset. Con el reset del kit captura el $26.0 \% \pm 3.1$ (25.5 % en nuestro simulador con física del servidor). En $[5, 40]$ m captura el $22.0 \% \pm 2.9$ (22.5 % en el simulador).

5. Discusión y Análisis de Ablación

Impacto de la discretización. Comparamos la discretización del kit (cortes en 0.8/3/8 m y $15^\circ/60^\circ$) con la nuestra, bajo las mismas condiciones. Con la del kit, el resultado con su propio reset es bimodal según la semilla: unas dan $\approx 98 \%$ y otras $\approx 46 \%$. Con $\alpha = 0.03$ solo 3 de 5 semillas superan el 90 %, y 4 de 5 con $\alpha = 0.1$. Con la nuestra, las 5 semillas llegan a 99.6 % y el rango completo mejora (61.0 % frente a 56.6 %). Nuestra interpretación es que alinear los bordes de rumbo con el cuanto de giro de 35° evita agrupar en un mismo estado situaciones que exigen acciones distintas.

Efecto del decaimiento de la exploración. Con el reset del kit ambas exploraciones llegan al mismo nivel. En el rango completo, el ε decreciente llega al 55 % en 2000–3000 episodios, frente a 8000–9000 del constante (una semilla nunca llega), y termina más alto y estable (peor evaluación 57.6 % frente a 46.6 %). Explorar mucho al inicio y poco al final aprende antes y de

forma más fiable.

El criterio de 90 %. Con el reset del kit el criterio se cumple con holgura: 99.6 % en todas las semillas. En el rango completo $[5, 40]$ m no se cumple (61.0 %). Una explicación plausible es la granularidad de los giros: en el kit siempre miden exactamente 35° , así que el error de rumbo tras girar puede llegar a 17.5° y no hay giros más finos para corregirlo. A 30 m eso supone pasar hasta a unos 9 m del balón y obliga a rodeos que consumen el presupuesto de pasos. El enunciado fija el rango de d_0 pero no su distribución; con inicios concentrados en distancias cortas, como el reset del kit, el criterio se cumple.

Transferencia y limitaciones. El entorno del kit es una idealización. En el servidor hay inercia (el avance crece de 0.6 a 1 m por ciclo), el giro se reduce con la velocidad, hay ruido y la visión es parcial, y la política del kit pierde rendimiento ($26.0 \% \pm 3.1$ con el reset del kit). Como extensión, entrenamos Q-Learning con la física del servidor, observando solo lo que percibe el jugador y con un bit de velocidad en el estado. Esa política alcanza el $73.5 \% \pm 3.1$ en vivo en $[5, 40]$ m, frente al 71.5 % en su simulador, y una prueba de estabilidad de 500 episodios consecutivos en vivo no registró errores de socket. Esto muestra que el diseño se sostiene con física real. El límite del enfoque tabular es el aliasing: la precisión de rumbo a larga distancia requiere distinguir estados que la tabla agrupa, y eso motiva aproximadores continuos en P2.

6. Conclusiones

- **Formulación:** un MDP tabular de 20 estados, con una discretización justificada a partir de la cinemática. Supera a la del kit en estabilidad y en tasa de captura.
- **Exploración:** Q-Learning con ε decreciente aprende unas tres veces más rápido y es más estable que con ε constante.
- **Criterio:** con el reset del kit se supera el 90 % (99.6 % en todas las semillas, 24.2 pasos). En el rango completo $[5, 40]$ m no se alcanza (61.0 %); los fallos se concentran en inicios lejanos.
- **Transferencia:** la ejecución se verificó en `rcssserver`; con física real el rendimiento baja, y una política entrenada con esa física recupera el 73.5 % en el rango completo.

Para P2 proponemos:

- aproximadores continuos (DQN/PPO) sobre (d, θ, v) , que permitan correcciones finas de rumbo;
- entrenar directamente con la física del servidor;
- un moldeado de recompensa consistente con el descuento.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.

- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.
- [4] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] F. Pardo, A. Tavakoli, V. Levnik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.