

Tareas Acotadas de RoboCup 2D con Métodos Tabulares: Persecución, Tiro, Conducción y Cooperación 2v1

Fase 1 (P1)

Grupo N° 1

Integrantes:

Leonardo Candio — leonardo.candio@utec.edu.pe

Dimaël Rivas — dimael.rivas@utec.edu.pe

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos como MDP tabulares las cuatro tareas acotadas del catálogo (persecución, tiro a puerta, conducción y cooperación 2v1) con la cinemática del *starter kit*, y comparamos Q-Learning, SARSA y Monte Carlo first-visit (con promedios y con α constante), cada uno con ϵ constante y decreciente, en 5 semillas. Medimos contra cotas exactas o constructivas y explicamos una diferencia entre métodos solo si un diagnóstico la aísla. La estructura de la tarea decide qué método conviene: con episodios de un paso y resultado estocástico (tiro) gana MC con promedios; con episodios largos y estados agregados (conducción, 2v1) los métodos TD aprenden antes o terminan mejor, y MC falla. La representación pesa más que el algoritmo. Verificamos la ejecución de las cuatro políticas en **rcssserver**.

1. Introducción

El catálogo propone cuatro tareas acotadas de RoboCup 2D y las implementamos todas: **persecución** (capturar un balón inmóvil, $d \leq 0.8$ m, a $d_0 \in [5, 40]$ m; criterio: captura > 90 % en menos de 40 pasos), **tiro a puerta**, **conducción** y **cooperación 2v1** (criterios en la Tabla 2). Todas usan la cinemática del **starter kit**: DASH y KICK desplazan una distancia exacta y TURN gira exactamente $\pm 35^\circ$, sin inercia ni ruido de movimiento y con observación completa. El simulador real [2, 3] se usa para **verificar la ejecución** conectando el cliente Python a **rcssserver** en Docker (`docker compose up -d`), con un entrenador que resetea episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

2.1. Persecución

Estados. El agente observa la distancia d al balón y su rumbo θ relativo al cuerpo: $s = (b_d(d), b_\theta(\theta))$, con 9 zonas de distancia y 11 sectores de rumbo ($|\mathcal{S}| = 99$, 396 valores Q ; Tabla 1), más un estado terminal de captura.

Componente	Bordes	Justificación
Rumbo b_θ	$\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$	La tolerancia angular de captura es $\arcsin(0.8/d)$: 4.6° a 10 m y 1.5° a 30 m, de ahí los sectores finos cerca del frente. 17.5° es la mitad del giro (el error máximo tras girar), 35° un giro y 90° separa delante/detrás.
Distancia b_d	3, 6, 10, 15, 20, 25, 30, 35 m	Con 1 m por paso, cada zona son 3-5 pasos de tiempo restante frente al presupuesto de 40; más finas cerca, donde se decide la maniobra final.

Tabla 1: Discretización de la persecución (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Acciones, transiciones y recompensa. $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } \pm 35\}$: DASH avanza 1 o 0.5 m en la dirección del cuerpo y TURN suma $\pm 35^\circ$. La dinámica es determinista sobre $(\mathbf{x}, \phi)$, pero sobre los bins $\mathcal{P}(s' | s, a)$ es estocástica: un TURN +35 lleva al frente un balón a 30° y no uno a 80° del mismo bin (aliasing). Recompensa del enunciado: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$; con $\gamma = 1$ el primer término es telescópico y maximizar G_0 equivale a capturar en menos pasos. Con $\gamma = 0.99$ el bono vale 67.6 en el paso 39 (con $\gamma = 0.9$, solo 1.6). El episodio termina con la captura o se trunca en $T_{max} = 40$, con bootstrap porque el tiempo no está en el estado [5].

2.2. Tiro a puerta, conducción y cooperación 2v1

La Tabla 2 resume las otras tres tareas, con la misma cinemática. Justificación:

- **Tiro.** Distancia y posición lateral determinan los ángulos a los postes con menos estados. El error es *angular*, así que crece con la distancia real al punto apuntado. σ , el alcance del arquero y p_{out} no están en el enunciado: los fijamos *antes de entrenar* con una regla escrita sobre el óptimo exacto (el tiro óptimo debe depender del arquero, CONDUCIR debe ser óptimo en algún estado y el óptimo con arquero, $< 100\%$); la regla cambió p_{out} de 0.1 a 0.02. Aun así CONDUCIR es óptimo en un solo estado, por 0.25 puntos: la tarea es, en la práctica, de **una sola decisión**.
- **Conducción.** 0.8 m es el radio de posesión (el del KICK), 2 m un KICK y 4 m la pérdida. **Quitamos** d_g : en todo episodio queda entre ≈ 32 y ≈ 92 m y no cambia la mejor acción.
- **2v1.** El agente controla al poseedor; compañero y defensor son guionados. Un bit indica si la línea de pase está bloqueada, que decide la intercepción. GIRAR se aleja del defensor, o gira hacia el centro si el defensor ya está detrás.

	Tiro a puerta	Conducción	Cooperación 2v1
Inicio	Balón a $d_g \sim U[11, 25]$ m de la línea de gol, $y \sim U[-10, 10]$ m; arquero con prob. 0.5 en $y_k \sim U[-3, 3]$ m	Jugador en $x_0 \sim U[-40, -10]$, $y_0 \sim U[-20, 20]$ m, rumbo al azar; balón 0.5 m adelante	Zona de 30×20 m; compañero a 6–10 m y defensor a 4–8 m del poseedor
$\mathcal{S}$	d_g : 11–15, 15–20, 20–25 m; lateral: izq., centro ($ y \leq 3.5$), der.; arquero: sin, izq., centro, der. $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_b : ≤ 0.8 , (0.8, 2], (2, 4] m; θ_b : frente $\pm 17.5^\circ$, izq., der.; θ_g (al arco): frente, izq., der., atrás $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_{comp} , d_{def} , θ_{comp} , θ_{def} (3 bins c/u); línea bloqueada; centro/banda $ \mathcal{S} = 324$
$\mathcal{A}$	Tiro a $y^* \in \{-6, -3.5, 0, 3.5, 6\}$ m y CONDUCCIR (+2 m, mínimo 11 m). $ \mathcal{A} = 6$	KICK 25 (balón +2 m si $d_b \leq 0.8$), DASH 80 (+0.8 m), TURN $\pm 35^\circ$. $ \mathcal{A} = 4$	PASE, DRIBLE (+1 m), GIRAR (35°), DESPEJE (fin, 0). $ \mathcal{A} = 4$
$\mathcal{P}$	Error angular $\epsilon \sim \mathcal{N}(0, (4^\circ)^2)$; afuera si $ y_c \geq 7.01$ m; atajado si $ y_c - y_k < 2$ m; con arquero, CONDUCCIR es bloqueado con prob. 0.02	Determinista	Defensor a 0.6 m/paso hacia el poseedor, rumbo con ruido $\mathcal{N}(0, 15^\circ)$; compañero a 0.6 m/paso hacia un punto de apoyo; intercepción con prob. 0.8 si la línea está bloqueada; quite con prob. 0.5 si $d_{def} < 1$ m
$\mathcal{R}$	+100 gol, −30 afuera, −50 atajado o bloqueado; −0.2 por CONDUCCIR	Δx del balón −0.1; −30 si $d_b > 4$ m o sale de la cancha; +50 al avanzar 30 m	+30 pase, −30 intercepción o quite, −10 fuera de la zona
γ, T_{max}	0.99; 10 (el tiro termina)	0.99; 100	0.99; 60
Criterio	Gol > 75 % sin y > 50 % con arquero	Avance de 30 m en > 80 %	Posesión > 50 pasos y ≥ 3 pases

Tabla 2: MDP de las otras tres tareas del catálogo, con la cinemática del kit.

3. Métodos y Protocolo Experimental

Comparamos cuatro reglas tabulares [1], con acciones ε -greedy, $Q_0 = 0$ y sin bootstrap en estados terminales: **Q-Learning** [4] (off-policy, $Q \leftarrow \alpha[r + \gamma \max_{a'} Q(s', a') - Q]$), **SARSA** (on-policy, con la acción a' realmente elegida), **MC first-visit con promedios** (paso $1/N$, el algoritmo del kit) y **MC first-visit con α constante** ($Q \leftarrow \alpha[G_t - Q]$). Exploración: $\varepsilon = 0.1$ constante frente a ε geométrico de 1 a 0.1, que llega al piso al 60 % del presupuesto (80 000, 50 000, 60 000 y 60 000 episodios en persecución, tiro, conducción y 2v1). $\alpha \in \{0.03, 0.1, 0.3\}$ se elige con un barrido en semillas 5–9 (por exploración en conducción y 2v1; en el tiro solo con ε decreciente; en la persecución $\alpha = 0.1$ fijo) y los resultados se reportan en las semillas 0–4. Periódicamente evaluamos la política greedy ($\varepsilon = 0$, sin aprendizaje) sobre 500 inicios fijos con el mismo ruido para todas las condiciones. Reportamos medias de 5 semillas con IC 95 % bootstrap y declaramos una diferencia solo si los IC no se solapan. Cada cifra tiene su artefacto (script, semilla y huella del código; notebooks 07 y 10–13).

4. Resultados y Análisis

4.1. Criterios, cotas y exploración

Cotas. Como el kit es determinista, para la persecución calculamos el mínimo exacto de pasos de cada inicio (A* con heurística admisible, 1 000 inicios): en [5, 40] m **ninguna política supera el 87.9 % $\pm$ 1.0**, porque 40 pasos de 1 m no alcanzan para girar y llegar desde 35–40 m (el óptimo captura allí el 18.7 %). Nuestro 85.7 % es el 97.5 % de ese máximo; la brecha está a 30–40 m, donde el óptimo usa correcciones que la tabla no representa. En el tiro, el óptimo exacto con arquero es 95.2 % y el de nuestros 36 estados 93.3 % (ruido de una evaluación: 1.1 %), así que

Tarea	Métrica	ϵ decreciente	ϵ constante	Referencia
Persecución, reset del kit	captura, final	100.0 [100.0, 100.0]	100.0 [100.0, 100.0]	óptimo 100
Persecución, [5, 40] m	captura, final	85.7 [85.4, 86.0]	84.3 [83.2, 85.6]	óptimo 87.9
Tiro, sin arquero	gol, final	100.0 [100.0, 100.0]	98.8 [98.1, 99.4]	óptimo 100
Tiro, con arquero	gol, final	92.3 [91.8, 92.6]	87.5 [85.6, 88.8]	óptimo repr. 93.3
Conducción	media últ. 5	97.7 [96.3, 99.0]	89.7 [83.8, 95.5]	guionado 100
Conducción	peor últ. 5	94.2 [90.1, 97.2]	71.6 [59.4, 84.0]	
2v1	media últ. 5	64.8 [61.3, 68.1]	65.5 [64.2, 67.4]	heurística 10.8

Tabla 3: Criterios y ablación de exploración de Q-Learning (política greedy; %, media de 5 semillas [IC 95 %]; en negrita, IC separados). Todas las tareas con criterio porcentual lo cumplen en las 5 semillas; en [5, 40] m el 90 % no es alcanzable.

Q-Learning está en el techo de su representación. En la conducción, un controlador guionado resuelve 20 000 de 20 000 inicios; en la 2v1 no hay cota y la heurística es solo una referencia.




Figura 1: Curvas de entrenamiento de Q-Learning (media móvil; banda: desv. est. entre 5 semillas): retorno descontado G_0 , éxito y pasos por episodio de los episodios de entrenamiento, que incluyen la exploración.

Lectura de las curvas (Figura 1). Miden la conducta *mientras explora*. Con ϵ decreciente el agente empieza casi al azar: G_0 arranca negativo en la persecución y la conducción, el éxito es nulo durante los primeros 10 000–20 000 episodios de la conducción y la 2v1, y los pasos reflejan el azar (en la conducción suben a ≈ 95 de 100 por timeouts antes de bajar a ≈ 72 ; en la 2v1 los episodios duran pocos pasos porque un DESPEJE aleatorio los termina). Con $\epsilon = 0.1$ la

conducta útil aparece mucho antes (en la conducción, en $\approx 3\,000$ episodios frente a $\approx 35\,000$), y ambas curvas se juntan cuando ε decreciente llega a su piso (60 % del presupuesto). El tiro es la excepción: con $\alpha = 0.03$ la curva de ε constante se estanca en ≈ 88 y la decreciente la supera desde $\approx 12\,000$ episodios. En la 2v1 el éxito al explorar queda en $\approx 12\%$ porque una acción aleatoria es DESPEJE con prob. 1/4; la política greedy llega al 65 %.

Qué muestra la ablación (Tabla 3). El efecto de ε decreciente depende de la tarea. En la persecución no hay diferencia final detectable; su ventaja es que la política *greedy* llega antes al 70 % (12 000 frente a 16 000 episodios), aunque al explorar el agente rinda peor (Figura 1). En la conducción termina mejor y con menos caídas. En el tiro termina mejor, pero es velocidad y no solución: la brecha se cierra con $\alpha = 0.1$, con $Q_0 = 100$ o con 4 veces más episodios (Figura 6a), porque con $Q_0 = 0$ y valores reales de 70–100 un paso de 0.03 corrige lento las acciones que $\varepsilon = 0.1$ casi no visita ($\max_a Q$ subestima V^* en 6.6 puntos). En la 2v1 no hay diferencia final.

4.2. Política y valor




Figura 2: Persecución: política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$, el mayor $Q(s, a)$ del estado (der.), aprendidos. Filas: distancia; columnas: rumbo relativo.




Figura 3: Tiro: acción y valor de inicio por estado, óptimos exactos de la representación (arriba) y aprendidos por Q-Learning, ε decreciente, semilla 0 (abajo). Tiro: y^* en m; COND: CONDUCIR.

En la persecución (Figura 2) la política avanza con el balón entre -35° y $+17.5^\circ$ y gira hacia él fuera de esa ventana; como la ventana es más ancha que un giro, tras girar el balón queda dentro y el agente no oscila. $\hat{V}$ crece al acercarse y alinearse, como el bono descontado. En el tiro podemos comparar con el óptimo exacto (Figura 3): la política aprendida tira a ± 3.5 m del lado contrario al arquero y coincide con π^* en 27 de 36 estados. Las diferencias se concentran con el arquero al centro o a la derecha, donde los valores exactos de las acciones están casi

empatados (69 frente a 70). CONDUCIR solo es óptimo en un estado y por 0.25 puntos: el tiro es, en la práctica, una decisión de un paso.

4.3. Trayectorias mientras aprende




Figura 4: Política greedy de Q-Learning (ϵ decreciente, semilla 0) antes de entrenar (arriba, $Q = 0$: desempates al azar) y al final (abajo), sobre los mismos inicios. Persecución: jugador (azul) y balón (blanco); tiro: tiros coloreados por resultado; conducción: balón (color) y jugador (gris); 2v1: balón (los pases son saltos rectos) y defensor (punteado).

En la Figura 4, los recorridos erráticos de la persecución se vuelven casi rectos; los tiros pasan de repartirse por el arco a ir al lado libre; en la conducción, las pérdidas inmediatas se vuelven avances rectos; y en la 2v1 el agente pasa de despejar a retener el balón 60 pasos con ≈ 20 pases: +30 por pase sin riesgo con la línea libre invita a pasar más de lo que exige el criterio.

Verificación en rcssserver. Ejecutamos cada política greedy en el servidor real, con 0 ciclos perdidos. En las tareas nuevas el estado se calcula con la verdad de terreno del entrenador (observación completa, como en su MDP): es una verificación de ejecución, no de transferencia.

Persecución (con la percepción del jugador): 26.0 % $\pm$ 3.1 con el reset del kit, porque la física real (aceleración gradual, giros que dependen de la velocidad, ruido) no es la del kit; una política entrenada con esa física alcanza el 73.5 % $\pm$ 3.1. **Tiro**: 20/20 goles sin arquero y 20/20 con un arquero quieto; el error angular real es de 1.75° frente a los 4° del modelo. **Conducción**: 10/10, aunque un KICK 25 real deja rodar el balón ≈ 13.6 m (no 2 m) y el jugador lo alcanza corriendo. **2v1**: 0/10, porque un pase real tarda varios ciclos (en el modelo es instantáneo) y el defensor llega antes.

5. Qué Método Conviene en Cada Tarea y Por Qué

Con estados, acciones, presupuesto e inicios iguales, las diferencias de la Tabla 4 y la Figura 5 vienen de cómo cada regla de actualización interactúa con la estructura de la tarea.

Episodios de un paso y resultado estocástico (tiro): MC con promedios. Los tiros

Tarea	Q-Learning	SARSA	MC (promedios)	MC (α constante)
Persecución, [5, 40] m	84.7 (77.0)	85.3 (83.3)	85.3 (84.3)	45.8 (43.2)
Tiro, con arquero	92.2 (90.9)	92.2 (90.5)	92.8 (92.6)	91.8 (90.0)
Conducción, 36 estados	97.7 (92.4)	94.3 (76.2)	90.4 (70.8)	30.1 (22.3)
Cooperación 2v1	64.8 (44.9)	54.2 (28.2)	7.8 (2.6)	20.7 (9.2)

Tabla 4: Éxito greedy (%): media de las últimas 5 evaluaciones y, entre paréntesis, AUC (éxito medio durante el entrenamiento; mayor = aprende antes). ε decreciente, 5 semillas. En negrita, el mejor de cada tarea y los que no se distinguen de él (IC 95 % solapados; IC en el notebook 13).




Figura 5: Éxito greedy de los cuatro métodos con ε decreciente (media de 5 semillas; banda: mínimo–máximo).




Figura 6: Diagnósticos. (a) Tiro con ε constante: tasa de gol final con el α elegido y $Q_0 = 0$, con $\alpha = 0.1$, con $Q_0 = 100$ y con 4 veces más episodios. (b) Conducción: media (barra) y peor (marca) de las últimas 5 evaluaciones con 36 y 245 estados (120 000 episodios). (c) 2v1: fracción de episodios de entrenamiento terminados por quite, según la probabilidad de quite.

terminan el episodio, así que Q-Learning y SARSA tienen la misma actualización (solo difieren al hacer bootstrap) y sus curvas coinciden. MC con promedios aprende antes (AUC 92.6 frente a 90.0–90.9) y es el único que no se retrasa con ε constante (93.2 frente a 86.0–86.6 %). El diagnóstico lo explica (Figura 6a): el paso $1/N$ fija Q en el primer retorno y luego da la media muestral de un resultado estacionario, mientras que un α constante pequeño arrastra el $Q_0 = 0$ inicial; subir α , usar $Q_0 = 100$ o entrenar más cierra la brecha. El sesgo de maximización esperado en Q-Learning no aparece: el máx solo entra tras CONDUCCIÓN.

Episodios largos y deterministas (persecución, conducción): métodos TD, con matices. En la persecución, con recompensa densa y sin riesgo, los tres métodos principales empatan al final: el techo lo pone la representación. En la conducción, Q-Learning aprende mucho antes (AUC 92.4 frente a 76.2 y 70.8). Es compatible con que Q-Learning, off-policy, aprenda la greedy mientras ε es alto y SARSA y MC estimen el valor de una política casi aleatoria, pero no lo aislamos: en la persecución Q-Learning es el más lento al inicio (Figura 5). La política

greedy de los métodos TD **oscila** (Figura 5): las caídas son ciclos TURN +35 / TURN -35 entre dos estados agregados con valores casi empatados (41.87 frente a 42.00), que una actualización pequeña invierte. Con 245 estados, Q-Learning y SARSA quedan en 100 % en cada una de las últimas evaluaciones (Figura 6b): la oscilación viene de la agregación. MC con promedios no oscila, pero se *congela* (curvas planas) y es el que más gana con la representación fina (de 64.5 a 97.8 %): contra lo que esperábamos, MC no resistió mejor la agregación [6]. Tampoco hubo un “acantilado” que hiciera a SARSA más prudente: al explorar, los métodos TD pierden el balón en ≤ 0.5 % de los episodios.

Episodios largos, estocásticos y con riesgo (2v1): Q-Learning. Q-Learning supera a SARSA con ambas exploraciones (≈ 11 puntos) y aprende antes. Aquí sí hay riesgo real, y aun así SARSA no es más prudente: al explorar sufre *más* quites que Q-Learning, y la diferencia no crece con la probabilidad de quite (Figura 6c). Con 1 944 estados rinde peor (62.4 frente a 67.9 %): la información extra no compensa los datos que exige.

MC en episodios largos. MC con α constante falla en las tres tareas largas (en la conducción, también con 245 estados y con $\alpha = 0.003$); MC con promedios falla en la 2v1, donde el 75 % de sus episodios greedy terminan en DESPEJE: regalar el balón (0) le resulta mejor que seguir. Es coherente con retornos largos y ruidosos y, con $1/N$, con conservar los retornos de políticas iniciales peores, pero no aislamos la causa.

6. Conclusiones

- **Criterios:** persecución, 100 % con el reset del kit (85.7 % en [5, 40] m, donde el óptimo es 87.9 %); tiro, 100 % y 92.3 %, en el techo de su representación; conducción, 97.7 %; 2v1, 65 %.
- **Métodos:** el mejor método depende de la estructura de la tarea. MC con promedios conviene cuando el episodio es un paso con resultado estocástico; con episodios largos conviene TD (Q-Learning, el más rápido en la conducción y el mejor en la 2v1) y MC falla. Son resultados de cuatro tareas, no reglas generales.
- **Representación y exploración:** la agregación de estados explica más que el algoritmo, y el efecto de ε decreciente depende de α y de la tarea. Para P2: aproximadores continuos (DQN/PPO) y la física del servidor.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [4] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [5] F. Pardo, A. Tavakoli, V. Levдик, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.
- [6] S. P. Singh, T. Jaakkola, and M. I. Jordan, “Learning without state-estimation in partially observable Markovian decision processes,” in *ICML*, 1994, pp. 284–292.