

Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

Fase 1 (P1)

Grupo N° 1

Integrantes:

Leonardo Candio — leonardo.candio@utec.edu.pe

Dimaël Rivas — dimaël.rivas@utec.edu.pe

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos la tarea de persecución de balón como un MDP tabular sobre el entorno cinemático del *starter kit* del curso: 99 estados (distancia y rumbo del balón) y 4 macro-acciones. Entrenamos Q-Learning con distancias iniciales en todo el rango del enunciado, $d_0 \in [5, 40]$ m. Con el reset del kit ($d_0 \approx 11\text{--}19$ m) la política captura el **100 %** de los balones en menos de 40 pasos en las 5 semillas, en 19.1 pasos (el óptimo exacto es 18.6). En el rango completo captura el $85.7\% \pm 0.3$. Calculamos por búsqueda exacta que **ninguna política puede superar el 87.9 %** en ese rango, así que el 90 % no es alcanzable allí y nuestra política llega al 97.5 % del óptimo. La exploración ϵ decreciente aprende antes que la constante (80 % en 12 000–16 000 episodios frente a 16 000–32 000). Validamos la ejecución conectando el cliente a `rcssserver`.

1. Introducción y Descripción de la Tarea

Elegimos la tarea acotada de **persecución e intercepción de balón**: el jugador parte de una posición y orientación arbitrarias, con el balón inmóvil a $d_0 \in [5, 40]$ m, y debe capturarlo ($d \leq 0.8$ m) en el menor tiempo posible. El criterio de éxito es una tasa de captura $> 90\%$ en menos de 40 pasos.

Como P1 consiste en tareas acotadas, usamos como **entorno principal el del starter kit** entregado por el profesor (`agente_cero_mc_control_persecucion.ipynb`), reimplementado fielmente en `src/kit_env.py`:

- DASH 100 avanza exactamente 1.0 m y DASH 50, 0.5 m;
- TURN ± 35 gira exactamente $\pm 35^\circ$;
- no hay inercia ni ruido, y el agente observa la distancia y el rumbo verdaderos.

Evaluamos con dos distribuciones de inicio:

- **[5, 40] m:** d_0 uniforme sobre el rango del enunciado, con posición y orientación arbitrarias. Se usa para entrenar y para la evaluación periódica.
- **Reset del kit:** jugador cerca de $(-15, 0)$ y balón cerca del centro, así que $d_0 \approx 11\text{--}19\text{ m}$.

El simulador real [2, 4] es un POMDP más difícil: inercia, giros que dependen de la velocidad, ruido y visión parcial. Lo usamos para **validar la transferencia**, conectando el cliente Python a `rcssserver` (Docker, `docker compose up -d`). El servidor corre controlado por un entrenador (coach offline), que resetea los episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

Espacio de estados ($\mathcal{S}$). El agente observa (d, θ) : la distancia al balón y su rumbo relativo al cuerpo. El estado es $s = (b_d(d), b_\theta(\theta))$, más un estado terminal de captura. Usamos 9 zonas de distancia y 11 sectores de rumbo: $|\mathcal{S}| = 9 \times 11 = 99$ estados y $99 \times 4 = 396$ valores Q (Tabla 1).

Componente	Bordes	Justificación
Rumbo b_θ	$\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$	La tolerancia angular de captura es $\arcsin(0.8/d)$: 4.6° a 10 m, 2.3° a 20 m y 1.5° a 30 m. Por eso se diseñaron sectores finos cerca del frente (aunque la política aprendida no cambia de acción entre ellos; Sección 5). 17.5° es la mitad del giro de 35° (el error máximo tras girar), 35° es un giro y 90° separa delante/detrás.
Distancia b_d	3, 6, 10, 15, 20, 25, 30, 35 m	Con 1 m por paso, cada zona equivale a 3–5 pasos de tiempo restante frente al presupuesto de 40. Las zonas son más finas cerca, donde se decide la maniobra final.

Tabla 1: Discretización del estado (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Espacio de acciones ($\mathcal{A}$). $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$. En el kit, con posición $\mathbf{x}$ y rumbo ϕ : **DASH** p : $\mathbf{x} += \ell_p(\cos \phi, \sin \phi)$ con $\ell_{100} = 1\text{ m}$ y $\ell_{50} = 0.5\text{ m}$; **TURN** ± 35 : $\phi += \pm 35^\circ$.

Transiciones ($\mathcal{P}$). Sobre el estado continuo $(\mathbf{x}, \phi)$ la dinámica es determinista. Sobre los bins, $\mathcal{P}(s' | s, a)$ es estocástica porque el estado no conserva la posición exacta dentro del bin. Un **TURN** $+35$ lleva al frente un balón a 30° , pero no uno a 80° , aunque ambos estén en el mismo bin. Es aliasing de estados; $\mathcal{S}$ es una aproximación, no un estado de Markov exacto.

Recompensa ($\mathcal{R}$). La del enunciado: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$. Con $\gamma = 1$ el término de aproximación es telescópico: $G_0 = (d_0 - d_T) - 0.2T + 100 \cdot \mathbb{I}\{\text{captura}\}$. Con captura, d_T es casi constante, así que maximizar G_0 equivale a capturar en el menor número de pasos. El moldeado basado en potencial con $\Phi = -d$ sería $d_t - \gamma d_{t+1}$ [3]. Con $\gamma < 1$ no afirmamos invariancia de la política.

Descuento y horizonte. $\gamma = 0.99$: el bono de captura vale $100 \cdot 0.99^{39} = 67.6$ en el paso 39; con $\gamma = 0.9$ valdría solo 1.6. El episodio termina con la captura (sin bootstrap) o se trunca en

$T_{max} = 40$ pasos. En el truncamiento se hace bootstrap desde s' , porque el tiempo no forma parte del estado [6].

3. Algoritmo de Aprendizaje por Refuerzo

Q-Learning [5, 1]: $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$, sin bootstrap en estados terminales, con acciones ε -greedy y desempate al azar. Comparamos dos exploraciones con el mismo nivel final:

- $\varepsilon = 0.1$ constante;
- $\varepsilon_k = \max(0.1, 1.0 \cdot d^k)$ con $d = 0.999952$, que llega al mínimo al 60 % del presupuesto.

Hiperparámetros. $\alpha = 0.1$, $\gamma = 0.99$, 80 000 episodios por corrida y 5 semillas por condición. Cada 4 000 episodios evaluamos la política greedy ($\varepsilon = 0$, sin aprendizaje) sobre 500 inicios fijos en [5, 40] m. Al final, evaluamos la Q-table también sobre 500 inicios del reset del kit. Guardamos la Q-table, el historial y la configuración de cada corrida.

Selección. Con R3 y las mismas condiciones, Q-Learning, SARSA y Monte Carlo first-visit (el algoritmo del kit) terminan empatados dentro del ruido entre semillas: ≈ 85 % en [5, 40] m y 100 % con el reset del kit. SARSA y MC alcanzan el 70 % antes. Reportamos Q-Learning.

4. Resultados Experimentales y Análisis

Fidelidad al kit. Con la configuración del notebook del kit (MC first-visit, 3 500 episodios, $\varepsilon = \max(0.05, 0.998^k)$, su discretización y su reset), nuestro entorno da 89.2 ± 17.2 (entre 44.8 % y 100 %) de éxito greedy en 8 semillas. El resultado de una sola semilla no es representativo; por eso reportamos siempre 5 semillas.

Máximo alcanzable. El kit es determinista, así que para cada inicio calculamos el mínimo exacto de pasos hasta capturar sobre todas las secuencias de acciones: una búsqueda A* con heurística admisible sobre posición y rumbo, 1 000 inicios por distribución y ningún caso indeterminado. Con el reset del kit el óptimo captura el 100 % en 18.6 pasos de media. En [5, 40] m **ninguna política puede superar el 87.9 % $\pm$ 1.0.**

Ablación de la exploración. La Tabla 2 y la Figura 1 resumen la ablación.

Exploración	$d_0 \in [5, 40]$ m			Reset del kit	
	Final < 40	Episodios a 70 % / 80 %	≤ 40	Captura < 40	Pasos
ε decreciente	0.857 ± 0.003	12k / 12k–16k	0.876	1.000 ± 0.000	19.1
$\varepsilon = 0.1$ constante	0.843 ± 0.013	16k / 16k–32k	0.863	1.000 ± 0.000	19.3
<i>Óptimo exacto</i>	<i>0.879</i>			<i>1.000</i>	<i>18.6</i>

Tabla 2: Ablación en el entorno del kit (Q-Learning, R3, greedy, 5 semillas). En [5, 40] m, $G_0 = 104.1$ con 26.3 pasos (decreciente) y $G_0 = 102.2$ con 26.6 pasos (constante).




Figura 1: Evaluación greedy durante el entrenamiento sobre 500 inicios fijos en $[5, 40]$ m (media $\pm$ desv. est. en 5 semillas). Referencias: criterio de 90 % y óptimo exacto (87.9 %).




Figura 2: Retorno G_0 y tasa de éxito de los episodios de entrenamiento (con exploración), media móvil de 500 episodios.

Política, valor y trayectorias. La Figura 3 muestra $\hat{\pi}(s)$ y $\hat{V}(s) = \max_a Q(s, a)$; son estimaciones aprendidas, no óptimos demostrados. La política avanza (DASH 100) cuando el balón está entre -35° y $+17.5^\circ$ y gira hacia él fuera de esa ventana, igual en casi todas las distancias. La ventana es más ancha que un giro de 35° , así que tras girar el balón queda dentro y el agente no oscila. La corrección fina ocurre por la geometría de la aproximación: al acercarse con un pequeño error, el rumbo del balón crece hasta cruzar un umbral y el agente gira. La Figura 4 muestra la política greedy guardada a lo largo del entrenamiento: las trayectorias pasan de erráticas a casi rectas.



Figura 3: Política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$ (der.) aprendidos en el entorno del kit (R3). Filas: distancia; columnas: rumbo relativo.




Figura 4: Trayectorias 2D de la política greedy tras N episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

Transferencia a rcssserver. Ejecutamos la política final en el servidor real, 200 episodios por distribución, con 0 comandos perdidos y 0 errores de reset. Con el reset del kit captura el $26.0\% \pm 3.1$ (26.0% en nuestro simulador con física del servidor); en $[5, 40]$ m, el $20.5\% \pm 2.9$ (21.0% en el simulador).

5. Discusión y Análisis de Ablación

Impacto de la discretización. Es el factor que más pesó. En $[5, 40]$ m, con 5 semillas:

- **Discretización del kit** (20 estados, cortes en $0.8/3/8$ m y $15^\circ/60^\circ$): 56.6% , y bimodal con su propio reset (según la semilla, $\approx 98\%$ o $\approx 46\%$).
- **Nuestra primera versión** (20 estados, alineada con el giro de 35°): 61.0% .

- **R3** (99 estados): 84.7 % con 80 000 episodios.
- **R4**, aún más fina (150 estados): cae a 81.0 %, porque tiene demasiados estados para el presupuesto de entrenamiento.

No aislamos qué componente de R3 explica la mejora. Agregar solo un sector de $\pm 5^\circ$ (R1, 28 estados) no ayudó. R3 añade además un borde en 35° y más zonas de distancia, y su política usa una ventana de avance asimétrica, $[-35^\circ, +17.5^\circ]$, que una rejilla sin borde en 35° no puede representar. Es una explicación compatible con los datos, no una demostración.

Efecto del decaimiento de la exploración. Con el reset del kit ambas exploraciones llegan a 100 %. En el rango completo, el ε decreciente alcanza el 70 % en 12 000 episodios en todas las semillas, frente a 16 000 del constante, y el 80 % en 12 000–16 000 frente a 16 000–32 000. También termina algo más alto y con menos varianza ($85.7 \% \pm 0.3$ frente a $84.3 \% \pm 1.3$). Explorar mucho al inicio y poco al final aprende antes y de forma más fiable.

¿Por qué no obtenemos mejores resultados? Con el reset del kit el criterio se cumple con holgura: 100 % en todas las semillas, a medio paso del óptimo. Los resultados peores tienen tres causas, todas medidas:

- **El presupuesto de 40 pasos no alcanza para los inicios lejanos.** Con 1 m por paso, un balón a 35–40 m exige casi todos los pasos solo para llegar, sin margen para girar ni corregir el rumbo. El óptimo exacto captura apenas el 18.7 % de esos inicios y el 87.9 % del rango completo con d_0 uniforme. Por eso el 90 % sobre $[5, 40]$ m no es alcanzable en este entorno con ningún algoritmo. Es un límite de la tarea tal como la interpretamos, no del aprendizaje. El enunciado fija el rango de d_0 pero no su distribución; con inicios concentrados en distancias cortas, como el reset del kit, el criterio se cumple.
- **La representación tabular deja una brecha pequeña con el óptimo** (85.7 % frente a 87.9 %). Hasta 30 m la política captura el 100 %, igual que el óptimo. La diferencia está a 30–40 m (85.7 % frente a 90.5 % entre 30 y 35 m; 8.2 % frente a 18.7 % entre 35 y 40 m), donde el óptimo usa maniobras precisas y la tabla aplica la misma ventana de avance en todas las distancias. Refinar más la tabla no ayudó: R4, con 150 estados, rindió menos que R3 porque necesita más datos de los que da el presupuesto.
- **La física del kit no es la del servidor real.** En `rcssserver` el avance crece gradualmente de 0.6 a 1 m por ciclo, el giro se reduce con la velocidad, hay ruido y la visión es parcial. La política aprende la cinemática idealizada del kit y en el servidor captura solo el $26.0 \% \pm 3.1$ con el reset del kit. Que coincida con nuestro simulador con física del servidor (26.0 %) indica que la pérdida se debe a la física, no a la conexión ni al cliente. Como extensión, entrenamos Q-Learning con la física del servidor, observando solo lo que percibe el jugador y con un bit de velocidad en el estado: esa política alcanza el $73.5 \% \pm 3.1$ en vivo en $[5, 40]$ m (71.5 % en su simulador), y una prueba de estabilidad de 500 episodios consecutivos en vivo no registró errores de socket.

6. Formulación MDP de las otras tareas del catálogo

El catálogo incluye otras tres tareas acotadas. Dejamos formulado su MDP con los mismos supuestos simples del kit:

- paso de tiempo discreto; DASH mueve al jugador una distancia exacta y TURN gira exactamente $\pm 35^\circ$;
- KICK desplaza el balón una distancia fija en la dirección del jugador, solo si está en posesión ($d_b \leq 0.8$ m);
- sin inercia ni ruido de movimiento, con observación completa y en la cancha de 105×68 m.

Las discretizaciones siguen la misma lógica que la persecución: 17.5° es la mitad del giro, las zonas de distancia reflejan pasos restantes y 0.8 m es el radio de posesión. Es una formulación propuesta; en esta entrega no la implementamos ni la entrenamos.

	Conducción y drible	Tiro a puerta	Cooperación 2v1
$\mathcal{S}$	d_b : ≤ 0.8 (posesión), $(0.8, 2]$, $(2, 4]$ m; θ_b : frente $\pm 17.5^\circ$, izq., der.; θ_g (rumbo al arco): frente, izq., der., atrás; d_g : < 20 , $20-40$, ≥ 40 m. $ \mathcal{S} = 3 \cdot 3 \cdot 4 \cdot 3 = 108$	d_g : 11–15, 15–20, 20–25 m; posición lateral: izq., centro, der. (equivale a $\theta_{post_l}, \theta_{post_r}$); arquero: sin arquero, izq., centro, der. $ \mathcal{S} = 3 \cdot 3 \cdot 4 = 36$	d_{comp} y d_{def} : < 5 , $5-10$, ≥ 10 m y < 2 , $2-5$, ≥ 5 m; θ_{comp} y θ_{def} : frente, lado, atrás; línea de pase bloqueada: sí/no; zona del balón: centro/banda. $ \mathcal{S} = 3^4 \cdot 2 \cdot 2 = 324$
$\mathcal{A}$	KICK 25 (balón +2 m), DASH 80 (+0.8 m), TURN $\pm 35^\circ$. $ \mathcal{A} = 4$	Tiro a 5 zonas del arco (poste izq., izq., centro, der., poste der.) y CONDUCCIR (+2 m hacia el arco). $ \mathcal{A} = 6$	PASE, DRIBLE (+1 m), GIRAR (35° alejándose del defensor), DESPEJE. $ \mathcal{A} = 4$
$\mathcal{P}$	Determinista (cinemática del kit). Se pierde el control si $d_b > 4$ m	Error lateral del tiro en la línea de gol $\epsilon \sim \mathcal{N}(0, (0.05 d_g)^2)$ m; arquero fijo en $y_k \sim U[-3, 3]$ m, que ataja si $ y - y_k < 1$ m	El defensor avanza 0.6 m/paso hacia el poseedor; el pase se intercepa con prob. 0.8 si la línea está bloqueada (defensor a < 1.5 m); quite con prob. 0.5 si $d_{def} < 1$ m. Tras un pase, el agente controla al nuevo poseedor
$\mathcal{R}$	Δx del balón hacia el arco -0.1 ; -30 si pierde el balón o sale de la cancha; $+50$ al avanzar 30 m	$+100$ gol, -30 tiro afuera, -50 tiro atajado; -0.2 por CONDUCCIR	$+30$ pase completado, -30 intercepción, -10 balón fuera; DESPEJE termina con 0
γ, T_{max}	0.99; 100 pasos	0.99; 10 pasos (termina al tirar)	0.99; 60 pasos
$ \mathcal{S} \times \mathcal{A} $	432	216	1 296
Criterio	Avance > 30 m con control en > 80 %	Gol > 75 % sin arquero y > 50 % con arquero	Posesión > 50 pasos y ≥ 3 pases

Tabla 3: Formulación MDP propuesta para las otras tres tareas del catálogo, con cinemática simple como la del kit. Estados terminales: pérdida, salida o éxito (conducción); tiro (tiro a puerta); intercepción, salida o despeje (2v1).

Justificación. En la conducción, 0.8 m separa tener el balón al pie de tenerlo cerca (hay que alcanzarlo antes de patear), y 4 m marca la pérdida de control. En el tiro, la distancia y la posición lateral determinan los ángulos a los postes, así que representarlas equivale a representar $(\theta_{post_l}, \theta_{post_r})$ con menos estados. En el 2v1, en vez de la geometría completa, un bit indica si la línea de pase está bloqueada, que es lo que decide el riesgo de intercepción. Las tres tablas ($\leq 1\,296$ valores) son manejables con los mismos algoritmos tabulares de este informe.

7. Conclusiones

- **Formulación:** un MDP tabular de 99 estados, con una discretización justificada a partir de la tolerancia angular de captura y del giro de 35° .
- **Exploración:** Q-Learning con ε decreciente aprende antes y es algo más estable que con ε constante.
- **Criterio:** con el reset del kit se supera el 90 % (100 % en todas las semillas, 19.1 pasos). En el rango completo $[5, 40]$ m el 90 % no es alcanzable para ninguna política (óptimo exacto 87.9 %), y la nuestra llega al 85.7 %, el 97.5 % de ese óptimo.
- **Transferencia:** la ejecución se verificó en `rcssserver`; con física real el rendimiento de la política del kit baja, y una política entrenada con esa física alcanza el 73.5 %.
- **Otras tareas:** dejamos formulado el MDP de conducción, tiro a puerta y cooperación 2v1 (Sección 6), con tablas de 216 a 1296 valores, pendientes de implementar.

Para P2 proponemos:

- aproximadores continuos (DQN/PPO) sobre (d, θ, v) , sin el costo en datos de una tabla fina;
- entrenar directamente con la física del servidor;
- un moldeado de recompensa consistente con el descuento.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.
- [4] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] F. Pardo, A. Tavakoli, V. Levnik, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.