

Persecución e Intercepción de Balón en RoboCup 2D con Q-Learning Tabular

Fase 1 (P1)

Grupo N° 1

Integrantes:

Leonardo Candio — leonardo.candio@utec.edu.pe

Dimaël Rivas — dimael.rivas@utec.edu.pe

Enlace al Repositorio de Código: <https://github.com/artrivas/RL-Project>

Resumen

Formulamos la tarea de persecución de balón como un MDP tabular sobre el entorno cinemático del *starter kit* del curso: 99 estados (distancia y rumbo del balón) y 4 macro-acciones. Entrenamos Q-Learning con distancias iniciales en todo el rango del enunciado, $d_0 \in [5, 40]$ m. Con el reset del kit ($d_0 \approx 11\text{--}19$ m) la política captura el **100 %** de los balones en menos de 40 pasos en las 5 semillas, en 19.1 pasos (el óptimo exacto es 18.6). En el rango completo captura el $85.7\% \pm 0.3$. Calculamos por búsqueda exacta que **ninguna política puede superar el 87.9 %** en ese rango, así que el 90 % no es alcanzable allí y nuestra política llega al 97.5 % del óptimo. La exploración ϵ decreciente aprende antes que la constante (80 % en 12 000–16 000 episodios frente a 16 000–32 000). Validamos la ejecución conectando el cliente a `rcssserver`.

1. Introducción y Descripción de la Tarea

Elegimos la tarea acotada de **persecución e intercepción de balón**: el jugador parte de una posición y orientación arbitrarias, con el balón inmóvil a $d_0 \in [5, 40]$ m, y debe capturarlo ($d \leq 0.8$ m) en el menor tiempo posible. El criterio de éxito es una tasa de captura $> 90\%$ en menos de 40 pasos.

Como P1 consiste en tareas acotadas, usamos como **entorno principal el del starter kit** entregado por el profesor (`agente_cero_mc_control_persecucion.ipynb`), reimplementado fielmente en `src/kit_env.py`:

- DASH 100 avanza exactamente 1.0 m y DASH 50, 0.5 m;
- TURN ± 35 gira exactamente $\pm 35^\circ$;
- no hay inercia ni ruido, y el agente observa la distancia y el rumbo verdaderos.

Evaluamos con dos distribuciones de inicio:

- **[5, 40] m:** d_0 uniforme sobre el rango del enunciado, con posición y orientación arbitrarias. Se usa para entrenar y para la evaluación periódica.
- **Reset del kit:** jugador cerca de $(-15, 0)$ y balón cerca del centro, así que $d_0 \approx 11\text{--}19\text{ m}$.

El simulador real [2, 4] es un POMDP más difícil: inercia, giros que dependen de la velocidad, ruido y visión parcial. Lo usamos para **validar la transferencia**, conectando el cliente Python a `rcssserver` (Docker, `docker compose up -d`). El servidor corre controlado por un entrenador (coach offline), que resetea los episodios y mide la verdad de terreno.

2. Modelado Formal como MDP

Espacio de estados ($\mathcal{S}$). El agente observa (d, θ) : la distancia al balón y su rumbo relativo al cuerpo. El estado es $s = (b_d(d), b_\theta(\theta))$, más un estado terminal de captura. Usamos 9 zonas de distancia y 11 sectores de rumbo: $|\mathcal{S}| = 9 \times 11 = 99$ estados y $99 \times 4 = 396$ valores Q (Tabla 1).

Componente	Bordes	Justificación
Rumbo b_θ	$\pm 2.5^\circ, \pm 7.5^\circ, \pm 17.5^\circ, \pm 35^\circ, \pm 90^\circ$	La tolerancia angular de captura es $\arcsin(0.8/d)$: 4.6° a 10 m, 2.3° a 20 m y 1.5° a 30 m. Por eso se diseñaron sectores finos cerca del frente (aunque la política aprendida no cambia de acción entre ellos; Sección 5). 17.5° es la mitad del giro de 35° (el error máximo tras girar), 35° es un giro y 90° separa delante/detrás.
Distancia b_d	3, 6, 10, 15, 20, 25, 30, 35 m	Con 1 m por paso, cada zona equivale a 3–5 pasos de tiempo restante frente al presupuesto de 40. Las zonas son más finas cerca, donde se decide la maniobra final.

Tabla 1: Discretización del estado (R3). Intervalos semiabiertos en distancia; en ángulo cada borde pertenece al bin más frontal.

Espacio de acciones ($\mathcal{A}$). $\mathcal{A} = \{\text{DASH } 100, \text{DASH } 50, \text{TURN } +35, \text{TURN } -35\}$. En el kit, con posición $\mathbf{x}$ y rumbo ϕ : **DASH** p : $\mathbf{x} += \ell_p(\cos \phi, \sin \phi)$ con $\ell_{100} = 1\text{ m}$ y $\ell_{50} = 0.5\text{ m}$; **TURN** ± 35 : $\phi += \pm 35^\circ$.

Transiciones ($\mathcal{P}$). Sobre el estado continuo $(\mathbf{x}, \phi)$ la dinámica es determinista. Sobre los bins, $\mathcal{P}(s' | s, a)$ es estocástica porque el estado no conserva la posición exacta dentro del bin. Un **TURN** $+35$ lleva al frente un balón a 30° , pero no uno a 80° , aunque ambos estén en el mismo bin. Es aliasing de estados; $\mathcal{S}$ es una aproximación, no un estado de Markov exacto.

Recompensa ($\mathcal{R}$). La del enunciado: $r_t = (d_t - d_{t+1}) - 0.2 + 100 \cdot \mathbb{I}\{d_{t+1} \leq 0.8\}$. Con $\gamma = 1$ el término de aproximación es telescópico: $G_0 = (d_0 - d_T) - 0.2T + 100 \cdot \mathbb{I}\{\text{captura}\}$. Con captura, d_T es casi constante, así que maximizar G_0 equivale a capturar en el menor número de pasos. El moldeado basado en potencial con $\Phi = -d$ sería $d_t - \gamma d_{t+1}$ [3]. Con $\gamma < 1$ no afirmamos invariancia de la política.

Descuento y horizonte. $\gamma = 0.99$: el bono de captura vale $100 \cdot 0.99^{39} = 67.6$ en el paso 39; con $\gamma = 0.9$ valdría solo 1.6. El episodio termina con la captura (sin bootstrap) o se trunca en

$T_{max} = 40$ pasos. En el truncamiento se hace bootstrap desde s' , porque el tiempo no forma parte del estado [6].

3. Algoritmo de Aprendizaje por Refuerzo

Q-Learning [5, 1]: $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$, sin bootstrap en estados terminales, con acciones ε -greedy y desempate al azar. Comparamos dos exploraciones con el mismo nivel final:

- $\varepsilon = 0.1$ constante;
- $\varepsilon_k = \max(0.1, 1.0 \cdot d^k)$ con $d = 0.999952$, que llega al mínimo al 60 % del presupuesto.

Hiperparámetros. $\alpha = 0.1$, $\gamma = 0.99$, 80 000 episodios por corrida y 5 semillas por condición. Cada 4 000 episodios evaluamos la política greedy ($\varepsilon = 0$, sin aprendizaje) sobre 500 inicios fijos en [5, 40] m. Al final, evaluamos la Q-table también sobre 500 inicios del reset del kit. Guardamos la Q-table, el historial y la configuración de cada corrida.

Selección. Con R3 y las mismas condiciones, Q-Learning, SARSA y Monte Carlo first-visit (el algoritmo del kit) terminan empatados dentro del ruido entre semillas: ≈ 85 % en [5, 40] m y 100 % con el reset del kit. SARSA y MC alcanzan el 70 % antes. Reportamos Q-Learning.

4. Resultados Experimentales y Análisis

Fidelidad al kit. Con la configuración del notebook del kit (MC first-visit, 3 500 episodios, $\varepsilon = \max(0.05, 0.998^k)$, su discretización y su reset), nuestro entorno da 89.2 ± 17.2 (entre 44.8 % y 100 %) de éxito greedy en 8 semillas. El resultado de una sola semilla no es representativo; por eso reportamos siempre 5 semillas.

Máximo alcanzable. El kit es determinista, así que para cada inicio calculamos el mínimo exacto de pasos hasta capturar sobre todas las secuencias de acciones: una búsqueda A* con heurística admisible sobre posición y rumbo, 1 000 inicios por distribución y ningún caso indeterminado. Con el reset del kit el óptimo captura el 100 % en 18.6 pasos de media. En [5, 40] m **ninguna política puede superar el 87.9 % $\pm$ 1.0.**

Ablación de la exploración. La Tabla 2 y la Figura 1 resumen la ablación.

Exploración	$d_0 \in [5, 40]$ m			Reset del kit	
	Final < 40	Episodios a 70 % / 80 %	≤ 40	Captura < 40	Pasos
ε decreciente	0.857 ± 0.003	12k / 12k–16k	0.876	1.000 ± 0.000	19.1
$\varepsilon = 0.1$ constante	0.843 ± 0.013	16k / 16k–32k	0.863	1.000 ± 0.000	19.3
<i>Óptimo exacto</i>	<i>0.879</i>			<i>1.000</i>	<i>18.6</i>

Tabla 2: Ablación en el entorno del kit (Q-Learning, R3, greedy, 5 semillas). En [5, 40] m, $G_0 = 104.1$ con 26.3 pasos (decreciente) y $G_0 = 102.2$ con 26.6 pasos (constante).




Figura 1: Evaluación greedy durante el entrenamiento sobre 500 inicios fijos en $[5, 40]$ m (media $\pm$ desv. est. en 5 semillas). Referencias: criterio de 90 % y óptimo exacto (87.9 %).




Figura 2: Retorno G_0 y tasa de éxito de los episodios de entrenamiento (con exploración), media móvil de 500 episodios.

Política, valor y trayectorias. La Figura 3 muestra $\hat{\pi}(s)$ y $\hat{V}(s) = \max_a Q(s, a)$; son estimaciones aprendidas, no óptimos demostrados. La política avanza (DASH 100) cuando el balón está entre -35° y $+17.5^\circ$ y gira hacia él fuera de esa ventana, igual en casi todas las distancias. La ventana es más ancha que un giro de 35° , así que tras girar el balón queda dentro y el agente no oscila. La corrección fina ocurre por la geometría de la aproximación: al acercarse con un pequeño error, el rumbo del balón crece hasta cruzar un umbral y el agente gira. La Figura 4 muestra la política greedy guardada a lo largo del entrenamiento: las trayectorias pasan de erráticas a casi rectas.



Figura 3: Política greedy $\hat{\pi}(s)$ (izq.) y valor $\hat{V}(s)$ (der.) aprendidos en el entorno del kit (R3). Filas: distancia; columnas: rumbo relativo.




Figura 4: Trayectorias 2D de la política greedy tras N episodios de entrenamiento (claro = temprano, oscuro = tarde), en 4 inicios del reset del kit. Círculo blanco: balón.

Transferencia a rcssserver. Ejecutamos la política final en el servidor real, 200 episodios por distribución, con 0 comandos perdidos y 0 errores de reset. Con el reset del kit captura el $26.0\% \pm 3.1$ (26.0% en nuestro simulador con física del servidor); en $[5, 40]$ m, el $20.5\% \pm 2.9$ (21.0% en el simulador).

5. Discusión y Análisis de Ablación

Impacto de la discretización. Es el factor que más pesó. En $[5, 40]$ m, con 5 semillas:

- **Discretización del kit** (20 estados, cortes en $0.8/3/8$ m y $15^\circ/60^\circ$): 56.6% , y bimodal con su propio reset (según la semilla, $\approx 98\%$ o $\approx 46\%$).
- **Nuestra primera versión** (20 estados, alineada con el giro de 35°): 61.0% .

- **R3** (99 estados): 84.7 % con 80 000 episodios.
- **R4**, aún más fina (150 estados): cae a 81.0 %, porque tiene demasiados estados para el presupuesto de entrenamiento.

No aislamos qué componente de R3 explica la mejora. Agregar solo un sector de $\pm 5^\circ$ (R1, 28 estados) no ayudó. R3 añade además un borde en 35° y más zonas de distancia, y su política usa una ventana de avance asimétrica, $[-35^\circ, +17.5^\circ]$, que una rejilla sin borde en 35° no puede representar. Es una explicación compatible con los datos, no una demostración.

Efecto del decaimiento de la exploración. Con el reset del kit ambas exploraciones llegan a 100 %. En el rango completo, el ε decreciente alcanza el 70 % en 12 000 episodios en todas las semillas, frente a 16 000 del constante, y el 80 % en 12 000–16 000 frente a 16 000–32 000. También termina algo más alto y con menos varianza ($85.7 \% \pm 0.3$ frente a $84.3 \% \pm 1.3$). Explorar mucho al inicio y poco al final aprende antes y de forma más fiable.

¿Por qué no obtenemos mejores resultados? Con el reset del kit el criterio se cumple con holgura: 100 % en todas las semillas, a medio paso del óptimo. Los resultados peores tienen tres causas, todas medidas:

- **El presupuesto de 40 pasos no alcanza para los inicios lejanos.** Con 1 m por paso, un balón a 35–40 m exige casi todos los pasos solo para llegar, sin margen para girar ni corregir el rumbo. El óptimo exacto captura apenas el 18.7 % de esos inicios y el 87.9 % del rango completo con d_0 uniforme. Por eso el 90 % sobre $[5, 40]$ m no es alcanzable en este entorno con ningún algoritmo. Es un límite de la tarea tal como la interpretamos, no del aprendizaje. El enunciado fija el rango de d_0 pero no su distribución; con inicios concentrados en distancias cortas, como el reset del kit, el criterio se cumple.
- **La representación tabular deja una brecha pequeña con el óptimo** (85.7 % frente a 87.9 %). Hasta 30 m la política captura el 100 %, igual que el óptimo. La diferencia está a 30–40 m (85.7 % frente a 90.5 % entre 30 y 35 m; 8.2 % frente a 18.7 % entre 35 y 40 m), donde el óptimo usa maniobras precisas y la tabla aplica la misma ventana de avance en todas las distancias. Refinar más la tabla no ayudó: R4, con 150 estados, rindió menos que R3 porque necesita más datos de los que da el presupuesto.
- **La física del kit no es la del servidor real.** En `rcssserver` el avance crece gradualmente de 0.6 a 1 m por ciclo, el giro se reduce con la velocidad, hay ruido y la visión es parcial. La política aprende la cinemática idealizada del kit y en el servidor captura solo el $26.0 \% \pm 3.1$ con el reset del kit. Que coincida con nuestro simulador con física del servidor (26.0 %) indica que la pérdida se debe a la física, no a la conexión ni al cliente. Como extensión, entrenamos Q-Learning con la física del servidor, observando solo lo que percibe el jugador y con un bit de velocidad en el estado: esa política alcanza el $73.5 \% \pm 3.1$ en vivo en $[5, 40]$ m (71.5 % en su simulador), y una prueba de estabilidad de 500 episodios consecutivos en vivo no registró errores de socket.

6. Conclusiones

- **Formulación:** un MDP tabular de 99 estados, con una discretización justificada a partir de la tolerancia angular de captura y del giro de 35° .
- **Exploración:** Q-Learning con ε decreciente aprende antes y es algo más estable que con ε constante.
- **Criterio:** con el reset del kit se supera el 90 % (100 % en todas las semillas, 19.1 pasos). En el rango completo $[5, 40]$ m el 90 % no es alcanzable para ninguna política (óptimo exacto 87.9 %), y la nuestra llega al 85.7 %, el 97.5 % de ese óptimo.
- **Transferencia:** la ejecución se verificó en `rcssserver`; con física real el rendimiento de la política del kit baja, y una política entrenada con esa física alcanza el 73.5 %.

Para P2 proponemos:

- aproximadores continuos (DQN/PPO) sobre (d, θ, v) , sin el costo en datos de una tabla fina;
- entrenar directamente con la física del servidor;
- un moldeado de recompensa consistente con el descuento.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97: Robot Soccer World Cup I*, Springer, 1998, pp. 62–79.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations: Theory and application to reward shaping,” in *ICML*, 1999, pp. 278–287.
- [4] M. Chen et al., *Users Manual: RoboCup Soccer Server*, RoboCup Federation, 2003.
- [5] C. J. C. H. Watkins and P. Dayan, “Q-learning,” *Machine Learning*, vol. 8, pp. 279–292, 1992.
- [6] F. Pardo, A. Tavakoli, V. Levдик, and P. Kormushev, “Time limits in reinforcement learning,” in *ICML*, 2018, pp. 4045–4054.